



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده ریاضی و علوم کامپیوتر

پیشنهاد رساله دکتری
گرایش محاسبات نرم و هوش مصنوعی

تطبیق دامنه برای شبکه‌های عمیق حافظ حریم
خصوصی جهت پردازش داده‌های اکتشاف مخازن
هیدروکربوری

نگارش
علی دانشپور

استادان راهنما
دکتر مهدی قطعی و دکتر محمدحسن شیرعلی شهرضا

استاد مشاور
دکتر علی اکبر نوریان

فروردین ۱۴۰۵

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

به نام خدا

تعهدنامه اصالت اثر

تاریخ: فروردین ۱۴۰۵

اینجانب **علی دانشپور** متعهد می‌شوم که مطالب مندرج در این پیشنهاد رساله حاصل کار پژوهشی اینجانب تحت نظارت و راهنمایی اساتید دانشگاه صنعتی امیرکبیر بوده و به دستاوردهای دیگران که در این پژوهش از آنها استفاده شده است مطابق مقررات و روال متعارف ارجاع و در فهرست منابع و مآخذ ذکر گردیده است. این پیشنهاد رساله قبلاً برای احراز هیچ مدرک هم‌سطح یا بالاتر ارائه نگردیده است. در صورت اثبات تخلف در هر زمان، مدرک تحصیلی صادر شده توسط دانشگاه از درجه اعتبار ساقط بوده و دانشگاه حق پیگیری قانونی خواهد داشت.

کلیه نتایج و حقوق حاصل از این پایان‌نامه متعلق به دانشگاه صنعتی امیرکبیر می‌باشد. هرگونه استفاده از نتایج علمی و عملی، واگذاری اطلاعات به دیگران یا چاپ و تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان‌نامه بدون موافقت کتبی دانشگاه صنعتی امیرکبیر ممنوع است. نقل مطالب با ذکر مآخذ بلامانع است.

علی دانشپور

امضا


چکیده

اکتشاف کارآمد و کم‌ریسک مخازن هیدروکربوری یکی از چالش‌های راهبردی صنعت نفت و گاز است. روش‌های متداول تفسیر داده‌های زمین‌شناسی علی‌رغم توسعه قابل توجه در دهه‌های اخیر، همچنان با محدودیت‌هایی نظیر وابستگی به تخصص افراد خبره، پیچیدگی بالای ساختار مخازن، عدم قطعیت در مدل‌سازی زیرسطحی و هزینه‌های زیاد عملیات اکتشافی مواجه‌اند. در سال‌های اخیر، رویکردهای یادگیری عمیق با توانایی استخراج خودکار الگوهای پیچیده از داده‌های حجیم، چشم‌انداز جدیدی برای بهبود فرآیند اکتشاف مخازن هیدروکربوری فراهم کرده‌اند. با این حال، طراحی و توسعه چارچوب‌هایی کارآمد، بهینه و امن همچنان از چالش‌های اساسی این حوزه به شمار می‌رود. هدف اصلی این پژوهش این است که با بهره‌مندی از رویکردهای پیشرفته یادگیری عمیق چارچوب‌هایی کارآمد و نوآورانه برای بهبود و تسهیل فرآیند اکتشاف مخازن هیدروکربوری ارائه شود. در فاز اول، چالش‌های عملیاتی پیش‌بینی لیتولوژی میان‌میدان مختلف بررسی می‌شود. اختلافات زمین‌شناسی و ناهمگنی مخازن باعث اختلاف توزیع داده‌ها می‌گردد. بنابراین از روش‌های تطبیق و تعمیم دامنه برای مدیریت این اختلافات استفاده می‌شود. در فاز دوم، با در نظر گرفتن احتمال وجود کلاس‌های لیتولوژیکی ناشناخته در میدان مقصد، استفاده از رویکردهای طبقه‌بندی مجموعه‌باز برای شناسایی و مدیریت این کلاس‌ها مدنظر قرار می‌گیرد. در فاز سوم، الزامات اصلی برای پیاده‌سازی صنعتی سامانه‌های هوشمند بررسی می‌شود. حفظ محرمانگی داده‌ها از طریق یادگیری مشارکتی امکان آموزش مدل‌ها بدون تبادل اطلاعات حساس را فراهم می‌کند. در فاز چهارم، هدف توسعه‌ی یک مجموعه‌داده‌ی مصنوعی با استفاده از مدل‌های انتشار است که امکان بهره‌برداری هم‌زمان از داده‌های چاه‌پیمایی و تصاویر مغزه را برای یک میدان را فراهم سازد. تولید مجموعه داده مصنوعی می‌تواند به‌طور موثری مشکل عدم‌توازن در داده‌های زمین‌شناسی را برطرف نماید. در فاز نهایی پژوهش، کارآمدی و تعمیم‌پذیری چارچوب‌های طراحی‌شده در فازهای گذشته با پیاده‌سازی آن‌ها بر دیتاست‌های مختلف در حوزه اکتشاف مخازن هیدروکربوری مورد ارزیابی قرار گیرد. تجمع فازهای اشاره‌شده، موجب افزایش قابلیت اطمینان، پایداری و پذیرش عملی مدل‌های هوش

مصنوعی در کاربردهای اکتشاف و ارزیابی مخازن هیدروکربوری می‌شود.

واژه‌های کلیدی:

لیتولوژی، یادگیری عمیق، یادگیری مشارکتی، تعمیم دامنه، هوش مصنوعی قابل اعتماد

فهرست مطالب

صفحه

عنوان

۱	مقدمه	۱
۱-۱	بیان مسئله	۲
۲-۱	تعریف مسئله	۳
۳-۱	اهمیت و کاربرد رساله	۴
۴-۱	مفروضات رساله	۵
۵-۱	چالش‌های رساله	۶
۱-۵-۱	محدودیت داده‌های برچسب‌دار در حوزه زمین‌شناسی	۶
۲-۵-۱	ناهمگنی و پیچیدگی ساختاری سازندهای زمین‌شناسی	۷
۳-۵-۱	نامتوازن بودن داده‌ها	۷
۴-۵-۱	عدم قطعیت و نویز در داده‌های چاه‌پیمایی	۸
۵-۵-۱	تعمیم‌پذیری مدل بین میادین و سازندهای مختلف	۹
۶-۵-۱	محدودیت دسترسی به داده‌های واقعی در صنایع نفت و گاز به دلیل	
۱۰	ملاحظات امنیتی و محرمانگی	۱۰
۶-۱	اهداف رساله	۱۰
۷-۱	سوالات پژوهش	۱۲
۲	مبانی نظری و پیشینه پژوهش	۱۳
۱-۲	مفاهیم و تعاریف اولیه	۱۴
۱-۱-۲	تعریف لیتولوژی	۱۴
۲-۱-۲	خواص پتروفیزیکی سنگ‌ها	۱۶
۳-۱-۲	تعریف چاه‌پیمایی	۱۹
۴-۱-۲	معرفی لیتولوژی‌های شاخص در مخازن هیدروکربنی	۱۹
۲-۲	پیش‌بینی لیتولوژی با استفاده از نمودارهای چاه‌پیمایی	۲۳
۳-۲	پیش‌بینی لیتولوژی با استفاده از تصاویر مغزه	۲۴
۴-۲	مروری جامع بر دیتاست‌های عمومی در حوزه‌ی تشخیص لیتولوژی	۲۵
۱-۴-۲	FORCE 2020	۲۵

۲۵	Southern Sichuan Well Log Lithofacies ۲-۴-۲
۲۷	Drill Core Image Dataset (DCID) ۳-۴-۲
۲۷	خلاصه و مقایسه‌ی دیتاست‌های عمومی در حوزه‌ی تشخیص لیتولوژی ۴-۴-۲
۲۸	جمع‌بندی ۵-۲
۲۹	۳ فازبندی رساله
۳۰	۱-۳ فاز اول: تطبیق دامنه برای کنترل ناهمگنی توزیع داده‌ها در میادین مختلف
۳۰	۱-۱-۳ تطبیق دامنه
۳۱	۲-۱-۳ تعمیم دامنه
۳۲	۲-۳ فاز دوم: شناسایی و مدیریت کلاس‌های لیتولوژیکی ناشناخته با بهره‌گیری از رویکردهای طبقه‌بندی مجموعه باز
۳۳	۱-۲-۳ طبقه‌بندی مجموعه باز
۳۴	۳-۳ فاز سوم: چارچوب حاکمیت و حفظ محرمانگی داده در شناسایی و مدیریت مخازن هیدروکربوری مبتنی بر یادگیری مشارکتی
۳۵	۴-۳ فاز چهارم: تولید مجموعه داده مصنوعی با استفاده از مدل‌های انتشار
۳۶	۱-۴-۳ چارچوب مفهومی تولید داده‌های مصنوعی
۳۷	۲-۴-۳ مزایا و پیامدهای پژوهشی فاز چهارم
۳۸	۳-۴-۳ جمع‌بندی
۳۸	۵-۳ فاز پنجم: پیاده‌سازی و ارزیابی چارچوب‌های پیشنهادی بر دیتاست‌های مختلف در حوزه اکتشاف مخازن هیدروکربوری
۴۰	۴ جمع‌بندی
۴۱	۱-۴ جمع‌بندی و یکپارچه‌سازی فازهای پیشنهاد رساله
۴۲	۲-۴ زمان‌بندی پیشنهادی اجرای رساله
۴۳	منابع و مراجع
۴۷	واژه‌نامه‌ی فارسی به انگلیسی
۴۹	واژه‌نامه‌ی انگلیسی به فارسی

فهرست اشکال

صفحه

شکل

۱-۲ ماتریس خطای مجموعه داده FORCE 2020 ۲۶

فهرست جداول

صفحه

جدول

- ۱-۲ خلاصه و مقایسه‌ی دیتاست‌های عمومی در حوزه‌ی تشخیص لیتولوژی ۲۷
- ۲-۲ خلاصه و مقایسه پژوهش‌های صورت گرفته در حوزه تشخیص لیتولوژی ۲۸
- ۱-۴ زمان‌بندی پیشنهادی پیشبرد و تکمیل فازهای مختلف رساله در بازه ۲۴ ماهه ۴۲

فصل اول

مقدمه

در این فصل ابتدا به معرفی مساله‌ی این پژوهش پرداخته و ضمن معرفی دقیق، اهمیت و کاربردهای آن را مورد بررسی قرار می‌دهیم. در ادامه چالش‌های این حوزه را مورد بررسی قرار داده و بعد از معرفی اهداف پژوهش، ساختار این پیشنهاد رساله را شرح می‌دهیم.

۱-۱ بیان مسئله

شناسایی و طبقه‌بندی لیتولوژی یکی از مراحل بنیادین در مطالعات زمین‌شناسی مخزن و اکتشاف منابع هیدروکربوری محسوب می‌شود. نوع لیتولوژی تأثیر مستقیمی بر ویژگی‌های پتروفیزیکی سنگ نظیر تخلخل، تراوایی، رفتار مکانیکی و ظرفیت ذخیره‌سازی سیالات دارد و از این‌رو نقش تعیین‌کننده‌ای در ارزیابی پتانسیل مخزنی سازندها ایفا می‌کند. در عمل، اطلاعات مربوط به لیتولوژی معمولاً از طریق داده‌های حاصل از چاه‌پیمایی، مطالعات مغزه و تحلیل‌های آزمایشگاهی به دست می‌آید. در میان این منابع، داده‌های چاه‌پیمایی به دلیل پوشش پیوسته در امتداد عمق چاه و هزینه کمتر نسبت به عملیات مغزه‌گیری، یکی از مهم‌ترین منابع اطلاعاتی برای تفسیر ویژگی‌های زیرسطحی به شمار می‌روند. با این حال، تبدیل پاسخ ابزارهای چاه‌پیمایی به اطلاعات دقیق لیتولوژیکی همواره یکی از چالش‌های مهم در مهندسی مخزن و زمین‌شناسی نفت بوده است.

روش‌های سنتی تفسیر داده‌های چاه‌پیمایی عمدتاً مبتنی بر روابط تجربی، نمودارهای متقاطع و قضاوت کارشناسی متخصصان زمین‌شناسی هستند. هرچند این روش‌ها در بسیاری از مطالعات کاربرد داشته‌اند، اما با افزایش حجم داده‌ها و پیچیده‌تر شدن ساختار سازندهای زمین‌شناسی، کارایی آن‌ها با محدودیت‌هایی مواجه شده است. روابط میان پاسخ‌های ابزارهای چاه‌پیمایی و ویژگی‌های لیتولوژیکی اغلب غیرخطی، چندبعدی و وابسته به شرایط زمین‌شناسی خاص هر میدان هستند؛ به همین دلیل، استخراج الگوهای دقیق از این داده‌ها با استفاده از روش‌های کلاسیک همواره با عدم قطعیت قابل توجهی همراه است. در سال‌های اخیر، پیشرفت‌های قابل توجه در حوزه یادگیری ماشین و یادگیری عمیق زمینه‌ای نوین برای تحلیل داده‌های زمین‌شناسی و بهبود فرآیند تفسیر داده‌های چاه‌پیمایی فراهم کرده است. این روش‌ها با قابلیت یادگیری الگوهای پیچیده و روابط غیرخطی از داده‌ها، پتانسیل بالایی برای بهبود دقت طبقه‌بندی لیتولوژی نشان داده‌اند.

در چارچوب این پژوهش، طبقه‌بندی لیتولوژی به‌عنوان یک مسئله پیش‌بینی داده‌محور در نظر گرفته می‌شود که در آن روابط پیچیده میان متغیرها وجود دارد. در این مسئله، مدل باید بتواند از داده‌های چاه‌پیمایی، که رفتارهایی غیرخطی و وابسته به ویژگی‌های فیزیکی سنگ دارند، الگوهای پنهان

را استخراج کرده و از آن‌ها برای تشخیص نوع لیتولوژی استفاده کند. داده‌های چاه‌پیمایی معمولاً به صورت سری‌های پیوسته در امتداد عمق ثبت می‌شوند. بنابراین مقدار هر ویژگی نه تنها بیانگر شرایط موضعی سازند در همان عمق است، بلکه می‌تواند تحت تأثیر ویژگی‌ها و شرایط لایه‌های مجاور نیز قرار گیرد. این موضوع سبب می‌شود مسئله طبقه‌بندی از حالت ساده‌ی نمونه‌های مستقل فراتر رفته و به مسئله‌ای با وابستگی‌های ساختاری و همبستگی‌های عمقی تبدیل شود.

علاوه بر داده‌های چاه‌پیمایی، اطلاعات حاصل از مغزه‌ها نیز منبع ارزشمندی برای شناخت مستقیم ویژگی‌های سنگ محسوب می‌شوند. به‌ویژه تصاویر مغزه می‌توانند اطلاعات دقیقی درباره ویژگی‌های بافتی، ساختاری و ترکیب سنگ‌ها فراهم کنند و به درک بهتر تغییرات لیتولوژیکی در مقیاس ریزتر کمک نمایند. ترکیب این اطلاعات با داده‌های چاه‌پیمایی می‌تواند به ارائه تصویری جامع‌تر از شرایط زیرسطحی و در نتیجه بهبود دقت مدل‌های طبقه‌بندی لیتولوژی منجر شود.

بر این اساس، مسئله اصلی این پژوهش بررسی و ارزیابی کارایی رویکردهای پیشرفته یادگیری ماشین در بهبود فرآیند تشخیص و طبقه‌بندی لیتولوژی با استفاده از داده‌های چاه‌پیمایی، تصاویر مغزه و سایر منابع اطلاعاتی مرتبط است. هدف آن است که با ارائه چارچوب‌ها و راهکارهای مناسب، محدودیت‌های موجود در روش‌های متداول کاهش یافته و امکان توسعه مدل‌هایی فراهم شود که در شرایط واقعی صنعت نفت و گاز از دقت، پایداری و قابلیت تعمیم‌پذیری بالاتری برخوردار باشند.

۲-۱ تعریف مسئله

در این پژوهش، مسئله اصلی به صورت یک مسئله شناسایی و طبقه‌بندی نوع لیتولوژی سنگ در اعماق مختلف زمین بر اساس داده‌های حاصل از عملیات چاه‌پیمایی و مغزه‌گیری تعریف می‌شود. این مسئله را می‌توان در قالب یک مسئله یادگیری ماشین نظارت‌شده تعریف کرد که در آن یک مدل با استفاده از داده‌های آموزشی، رابطه میان ویژگی‌های اندازه‌گیری‌شده و کلاس لیتولوژی متناظر را فرا می‌گیرد. فرض کنید مجموعه داده‌ای شامل N نمونه و هر نمونه با M ویژگی توصیف شود. در این صورت داده‌ها را می‌توان به صورت یک ماتریس ویژگی به شکل $X \in \mathbb{R}^{N \times M}$ نمایش داد.

که در آن هر سطر از ماتریس X متناظر با یک نمونه (به عنوان مثال یک نقطه عمقی در چاه) و هر ستون بیانگر یکی از ویژگی‌های اندازه‌گیری‌شده توسط ابزارهای چاه‌پیمایی است. بنابراین مقدار عنصر x_{ij} نشان‌دهنده مقدار ویژگی j برای نمونه i خواهد بود. این ویژگی‌ها می‌توانند شامل انواع لاگ‌های چاه‌پیمایی مانند Gamma Ray، Resistivity، Density، Neutron و ... باشند که اطلاعاتی

درباره خصوصیات فیزیکی و ترکیب سنگ ارائه می‌دهند.

در کنار ماتریس ویژگی‌ها، یک بردار برچسب نیز به صورت $Y = \{y_1, y_2, \dots, y_n\}$ در نظر گرفته می‌شود که نوع لیتولوژی هر نمونه را مشخص می‌کند. در این بردار y_i نشان‌دهنده کلاس لیتولوژی متناظر با نمونه i ام است. در حالت کلی، مسئله طبقه‌بندی لیتولوژی را می‌توان به صورت یادگیری یک تابع نگاشت از فضای ویژگی‌ها به فضای برچسب‌ها به صورت زیر تعریف کرد:

$$f : X \rightarrow Y \quad (1-1)$$

به عبارت دیگر، هدف یادگیری مدلی است که بتواند با دریافت بردار ویژگی یک نمونه جدید، کلاس لیتولوژی متناظر با آن را پیش‌بینی کند. اگر مجموعه لیتولوژی‌های مورد نظر شامل K کلاس مختلف باشد، آنگاه مسئله به صورت یک مسئله طبقه‌بندی چنددسته‌ای به صورت زیر قابل بیان است:

$$f : \mathbb{R}^M \rightarrow \{1, 2, \dots, K\} \quad (2-1)$$

خروجی مدل، یکی از کلاس‌های لیتولوژی تعریف‌شده را به هر نمونه اختصاص می‌دهد.

۳-۱ اهمیت و کاربرد رساله

طبقه‌بندی دقیق لیتولوژی نقش اساسی در درک ویژگی‌های زمین‌شناسی مخازن هیدروکربوری و کاهش عدم قطعیت در مطالعات زیرسطحی دارد، زیرا نوع سنگ ارتباط مستقیمی با خصوصیات پتروفیزیکی و رفتار سیالات در مخزن دارد. نتایج حاصل از طبقه‌بندی لیتولوژی به طور گسترده در مدل‌سازی زمین‌شناسی و ساخت مدل‌های سه‌بعدی مخزن، ارزیابی کیفیت مخزن و شناسایی لایه‌های مستعد تولید، تفکیک واحدهای مخزنی از لایه‌های غیرمخزنی، و برآورد پارامترهایی مانند ضخامت خالص مخزن مورد استفاده قرار می‌گیرد. علاوه بر این، اطلاعات لیتولوژیکی استخراج‌شده از داده‌های چاه‌پیمایی می‌تواند به تفسیر سریع‌تر و دقیق‌تر داده‌های زیرسطحی، بهبود تصمیم‌گیری در مکان‌یابی چاه‌ها و برنامه‌ریزی توسعه میدان، و همچنین پشتیبانی از مطالعات ژئومکانیکی و طراحی عملیات حفاری و تکمیل چاه کمک کند. از این‌رو، توسعه روش‌های پیشرفته مبتنی بر یادگیری ماشین برای طبقه‌بندی دقیق لیتولوژی می‌تواند نقش مؤثری در افزایش دقت تحلیل داده‌های چاه‌پیمایی و ارتقای کیفیت تصمیم‌گیری‌های مهندسی در صنعت نفت و گاز ایفا نماید.

۴-۱ مفروضات رساله

به منظور صورت‌بندی مسئله و فراهم‌سازی چارچوبی منسجم برای توسعه و ارزیابی مدل‌های یادگیری ماشین در تشخیص لیتولوژی، مجموعه‌ای از مفروضات در این پژوهش در نظر گرفته شده است. این مفروضات با هدف ساده‌سازی مسئله و امکان‌پذیر ساختن مدل‌سازی داده‌های زیرسطحی اتخاذ شده‌اند. هرچند در شرایط واقعی ممکن است برخی از این فرض‌ها به‌طور کامل برقرار نباشند، اما در بسیاری از مطالعات زمین‌شناسی مخزن و تحلیل داده‌های چاه‌پیمایی به‌عنوان تقریب‌هایی قابل قبول مورد استفاده قرار می‌گیرند.

• ثابت فرض کردن لیتولوژی در بازه‌های عمقی نمونه‌برداری:

در این پژوهش فرض می‌شود که نوع لیتولوژی در هر بازه عمقی نمونه‌برداری ثابت است. به بیان دیگر، برای هر گام ثبت داده در لاگ‌های چاه‌پیمایی (برای مثال در فاصله‌های نمونه‌برداری مشخص)، تنها یک لیتولوژی غالب در نظر گرفته شده و همان لیتولوژی به‌عنوان برچسب آن بازه عمقی در نظر گرفته می‌شود.

در محیط‌های رسوبی طبیعی، تغییرات لیتولوژیکی ممکن است در مقیاس‌هایی کوچک‌تر از فاصله نمونه‌برداری ابزارهای چاه‌پیمایی رخ دهند. با این حال، چنین تغییرات ریزمقیاسی معمولاً در داده‌های لاگ قابل تفکیک نیستند. این محدودیت عمدتاً ناشی از تفکیک‌پذیری عمقی ابزارهای چاه‌پیمایی و همچنین ماهیت فرآیند برچسب‌گذاری داده‌ها است که اغلب بر پایه تفسیرهای زمین‌شناسی، اطلاعات مغزه و یا داده‌های جانبی انجام می‌شود. در نتیجه، تغییرات لیتولوژیکی در مقیاس‌های کوچک‌تر از فاصله نمونه‌برداری در چارچوب این پژوهش قابل تشخیص فرض نشده و هر بازه نمونه‌برداری به‌صورت یک واحد لیتولوژیکی همگن در نظر گرفته می‌شود. این فرض به‌عنوان یک تقریب عملی در بسیاری از مطالعات مشابه [۱، ۲] متداول و پذیرفته شده است.

• همگنی نسبی داده‌ها در یک میدان نفتی:

در این پژوهش فرض می‌شود داده‌های چاه‌پیمایی به‌دست‌آمده از چاه‌های مختلف یک میدان نفتی، از نظر ویژگی‌های آماری و الگوهای پاسخ ابزارها تا حد قابل قبولی مشابه هستند. به عبارت دیگر، داده‌های حاصل از این چاه‌ها می‌توانند به‌عنوان نمونه‌هایی از یک توزیع داده مشترک در نظر گرفته شوند.

این فرض امکان تجمع داده‌های چندین چاه و استفاده از آن‌ها برای آموزش مدل‌های یادگیری

ماشین را فراهم می‌کند. چنین رویکردی به‌ویژه در شرایطی که داده‌های برچسب‌دار محدود هستند اهمیت دارد. با توجه به اینکه چاه‌های مورد مطالعه در یک میدان نفتی و در چارچوب زمین‌شناسی نسبتاً مشابهی قرار دارند، انتظار می‌رود ویژگی‌های اصلی پاسخ لاگ‌ها تحت تأثیر شرایط زمین‌شناسی مشابهی شکل گرفته باشند.

• پایداری نسبی شرایط حفاری و محیط چاه در زمان ثبت لاگ‌ها:

در این پژوهش فرض می‌شود شرایط حفاری و محیط چاه در طول فرآیند ثبت داده‌های چاه‌پیمایی دچار تغییرات شدید و ناگهانی نشده است. عواملی نظیر تغییرات قابل توجه در نوع سیال حفاری، تغییرات چشمگیر در قطر چاه، ناپایداری دیواره چاه و اختلال در عملکرد ابزارهای اندازه‌گیری می‌توانند پاسخ ثبت‌شده در لاگ‌ها را تحت تأثیر قرار دهند.

با این حال، در چارچوب این مطالعه فرض می‌شود چنین عوامل محیطی یا عملیاتی در حدی نبوده‌اند که الگوهای اصلی موجود در داده‌های لاگ را به‌طور اساسی دچار اعوجاج کنند. به بیان دیگر، فرض می‌شود داده‌های ثبت‌شده نمایانگر پاسخ واقعی سازند بوده و اثرات محیطی احتمالی در حد قابل قبولی کنترل یا اصلاح شده‌اند.

مفروضات فوق چارچوبی ساده‌سازی‌شده اما قابل اتکا برای تحلیل داده‌های چاه‌پیمایی و توسعه مدل‌های یادگیری ماشین فراهم می‌کنند. این مفروضات امکان مدل‌سازی سیستماتیک داده‌های زیرسطحی را فراهم ساخته و با رویه‌های متداول در بسیاری از مطالعات مرتبط با مدل‌سازی داده‌های زمین‌شناسی سازگار هستند [۳، ۴].

۵-۱ چالش‌های رساله

در این بخش، مهم‌ترین چالش‌های پیش‌روی این پژوهش معرفی و مورد بررسی قرار می‌گیرند.

۱-۵-۱ محدودیت داده‌های برچسب‌دار در حوزه زمین‌شناسی

یکی از چالش‌های مهم در کاربرد روش‌های یادگیری نظارت‌شده برای طبقه‌بندی لیتولوژی، محدودیت دسترسی به داده‌های برچسب‌دار با کیفیت بالا است. تعیین دقیق لیتولوژی معمولاً مستلزم انجام مطالعات آزمایشگاهی، بررسی مغزه‌ها و تحلیل‌های تخصصی زمین‌شناسی است که فرآیندی زمان‌بر، پرهزینه و

محدود به تعداد مشخصی از چاه‌ها و بازه‌های عمقی است. در نتیجه، در بسیاری از پروژه‌ها تنها بخش محدودی از داده‌های چاه‌پیمایی دارای برچسب‌های لیتولوژیکی معتبر هستند. کمبود داده‌های برچسب‌دار می‌تواند فرآیند آموزش مدل‌های یادگیری عمیق را با محدودیت مواجه کند، زیرا این مدل‌ها برای دستیابی به عملکرد مطلوب معمولاً به حجم قابل توجهی از داده‌های آموزشی نیاز دارند. علاوه بر این، توزیع مکانی محدود داده‌های برچسب‌دار ممکن است موجب کاهش قابلیت تعمیم مدل به سایر چاه‌ها یا بخش‌های مختلف میدان شود. از این‌رو، توسعه رویکردهایی که بتوانند از داده‌های محدود به‌صورت مؤثر استفاده کنند، یکی از موضوعات مهم در پژوهش‌های مرتبط با کاربرد هوش مصنوعی در تشخیص لیتولوژی به شمار می‌رود.

۱-۵-۲ ناهمگنی و پیچیدگی ساختاری سازندهای زمین‌شناسی

سازندهای زمین‌شناسی به‌طور ذاتی دارای ناهمگنی قابل توجهی در مقیاس‌های مختلف مکانی هستند. تغییرات در ترکیب کانی‌شناسی، بافت سنگ، درجه سیمانی‌شدن، میزان تخلخل و سایر ویژگی‌های پتروفیزیکی می‌تواند حتی در فواصل کوتاه عمقی نیز رخ دهد. این ناهمگنی‌های چندمقیاسی موجب می‌شوند پاسخ ابزارهای چاه‌پیمایی برای لیتولوژی‌های مختلف در بسیاری از موارد دارای هم‌پوشانی باشد و مرزهای مشخص و قطعی میان کلاس‌های لیتولوژیکی به‌سادگی قابل تشخیص نباشد. در چنین شرایطی، استخراج روابط دقیق میان پاسخ‌های لاگ و نوع لیتولوژی به مسئله‌ای پیچیده تبدیل می‌شود. روابط میان متغیرهای پتروفیزیکی و لیتولوژی اغلب غیرخطی و چندبعدی هستند و تحت تأثیر عوامل زمین‌شناسی متعددی قرار دارند. بنابراین، توسعه مدل‌هایی که قادر به شناسایی و مدل‌سازی این روابط پیچیده باشند، یکی از چالش‌های مهم در کاربرد روش‌های یادگیری عمیق برای تفسیر داده‌های زیرسطحی محسوب می‌شود.

۱-۵-۳ نامتوازن بودن داده‌ها

یکی از چالش‌های بنیادین در کاربرد روش‌های یادگیری عمیق برای طبقه‌بندی لیتولوژی، نامتوازن^۱ بودن توزیع کلاس‌ها در داده‌های زمین‌شناسی است. در بسیاری از مجموعه‌داده‌های حاصل از چاه‌پیمایی، مغزه‌نگاری و مطالعات مخزنی، فراوانی وقوع انواع مختلف لیتولوژی به‌صورت یکنواخت توزیع نشده و برخی واحدهای سنگی به‌طور طبیعی سهم بسیار بیشتری از داده‌ها را به خود اختصاص می‌دهند، در حالی که

¹ Imbalanced

سایر لیتولوژی‌ها تنها در بازه‌های محدود عمقی یا در شرایط زمین‌شناسی خاص مشاهده می‌شوند. این ویژگی ذاتی داده‌های زمین‌شناسی موجب شکل‌گیری مجموعه داده‌هایی با توزیع نامتوازن کلاس‌ها می‌شود که می‌تواند بر فرآیند آموزش و تعمیم‌پذیری^۲ مدل‌های یادگیری ماشین تأثیر قابل توجهی داشته باشد.

در چنین شرایطی، بسیاری از الگوریتم‌های یادگیری ماشین که بر فرض توزیع نسبتاً متوازن داده‌ها استوار هستند، در فرآیند آموزش به سمت کلاس‌های پرتکرار سوگیری^۳ پیدا می‌کنند. در نتیجه، مدل تمایل دارد الگوهای مرتبط با لیتولوژی‌های غالب را با دقت بیشتری فراگیرد، در حالی که توانایی آن در شناسایی و تفکیک لیتولوژی‌های کم‌نمونه یا نادر به‌طور محسوسی کاهش می‌یابد [۵]. این مسئله به‌ویژه در کاربردهای زمین‌شناسی و مهندسی مخزن از اهمیت ویژه‌ای برخوردار است، زیرا برخی از لیتولوژی‌های کم‌فراوان ممکن است از نظر مخزنی یا ژئومکانیکی نقش تعیین‌کننده‌ای در رفتار مخزن داشته باشند.

علاوه بر این، نامتوازن بودن داده‌ها می‌تواند فرآیند ارزیابی عملکرد مدل را نیز تحت تأثیر قرار دهد. به‌طور خاص، استفاده از معیارهای کلی ارزیابی نظیر دقت در مجموعه داده‌های نامتوازن ممکن است منجر به ارائه برآوردی بیش از حد خوش‌بینانه از عملکرد مدل شود، زیرا این معیارها غالباً تحت تأثیر عملکرد مدل در پیش‌بینی کلاس‌های پرتکرار قرار می‌گیرند و قادر به بازتاب دقیق توانایی مدل در شناسایی کلاس‌های کم‌نمونه نیستند.

از این‌رو، مسئله نامتوازن بودن داده‌ها به‌عنوان یکی از چالش‌های اساسی در توسعه مدل‌های مبتنی بر یادگیری ماشین و یادگیری عمیق برای طبقه‌بندی لیتولوژی مطرح است و مدیریت مناسب آن، از طریق به‌کارگیری راهبردهای مؤثر در مرحله آماده‌سازی داده‌ها، آموزش مدل و ارزیابی عملکرد، نقش مهمی در بهبود قابلیت تعمیم و اعتمادپذیری مدل‌های پیش‌بینی ایفا می‌کند [۶].

۱-۵-۴ عدم قطعیت و نویز در داده‌های چاه‌پیمایی

داده‌های حاصل از ابزارهای چاه‌پیمایی به‌طور ذاتی با درجاتی از عدم قطعیت و نویز همراه هستند. عملکرد ابزارها تحت تأثیر عواملی همچون شرایط عملیاتی درون چاه، نوع و خواص سیال حفاری، ناپیوستگی‌ها و ناصافی دیواره چاه، تغییرات رئولوژی^۴ سیال و محدودیت‌های تکنیکی سامانه‌های اندازه‌گیری قرار دارد.

^۲Generalization

^۳Bias

^۴Rheology

این عوامل می‌توانند منجر به انحرافات سیستماتیک، نوسانات تصادفی و خطاهای وابسته به محیط شوند؛ در نتیجه، مقادیر ثبت‌شده در لاگ‌ها الزاماً بازتاب مستقیم و بی‌نقصی از ویژگی‌های واقعی سازند نیستند. وجود چنین نویز و عدم قطعیتی در داده‌های ورودی، چالشی مهم برای مدل‌های یادگیری ماشین ایجاد می‌کند. این مدل‌ها به‌ویژه در شرایط محدودیت داده، نسبت به الگوهای تصادفی و ناپایدار حساس هستند و ممکن است نویز را به‌عنوان الگوی ساختاری یاد بگیرند، پدیده‌ای که به بیش‌برازش^۵ نسبت به نویز منجر می‌شود. نتیجه این امر کاهش چشمگیر پایداری^۶ مدل، ضعف در تعمیم به داده‌های جدید و افزایش نوسان عملکرد در سازندها یا چاه‌های متفاوت است.

از این‌رو، مدیریت عدم قطعیت تنها با اتکا به پیش‌پردازش کلاسیک داده‌ها به‌طور کامل قابل دستیابی نیست، زیرا بخشی از عدم قطعیت، ماهیت فیزیکی و غیرقابل حذف دارد. در چنین شرایطی، توسعه مدل‌هایی که مقاومت ذاتی در برابر نویز داده‌ها داشته باشند اهمیت ویژه‌ای پیدا می‌کند. به‌کارگیری رویکردهایی نظیر مدل‌های احتمالاتی^۷ و روش‌های مبتنی بر کمی‌سازی عدم قطعیت^۸ مدل می‌تواند نقش کلیدی در بهبود قابلیت اعتماد و پایداری مدل ایفا کند.

۱-۵-۵ تعمیم‌پذیری مدل بین میادین و سازندهای مختلف

یکی از چالش‌های مهم در کاربرد روش‌های یادگیری عمیق در پیش‌بینی لیتولوژی، مسئله تعمیم‌پذیری مدل‌ها بین میادین و سازندهای زمین‌شناسی مختلف است. مدل‌هایی که بر اساس داده‌های یک میدان نفتی یا یک سازند خاص آموزش داده می‌شوند، معمولاً الگوهای آماری و روابط موجود در همان مجموعه داده را فرا می‌گیرند. با این حال، ویژگی‌های زمین‌شناسی نظیر ترکیب کانی‌شناسی، محیط رسوبی، تاریخچه زمین‌ساختی و خواص پتروفیزیکی سنگ‌ها می‌توانند بین میادین و حتی در بخش‌های مختلف یک حوضه رسوبی به‌طور قابل توجهی متفاوت باشند.

این تفاوت‌های زمین‌شناسی موجب می‌شود پاسخ ابزارهای چاه‌پیمایی برای لیتولوژی‌های مشابه در میادین مختلف دارای الگوهای متفاوتی باشد. در نتیجه، مدلی که در یک منطقه عملکرد مطلوبی دارد ممکن است در هنگام استفاده در میدان یا سازند دیگر با کاهش قابل توجه دقت پیش‌بینی مواجه شود. این مسئله به‌ویژه در کاربردهای عملی صنعت نفت و گاز اهمیت دارد، زیرا بسیاری از پروژه‌های اکتشاف و توسعه مخزن مستلزم استفاده از مدل‌هایی هستند که بتوانند در شرایط زمین‌شناسی متنوع عملکرد

^۵Overfitting

^۶Robustness

^۷Probabilistic Models

^۸Uncertainty Quantification

قابل قبولی داشته باشند.

از سوی دیگر، جمع‌آوری داده‌های برجسب‌دار جدید برای هر میدان یا سازند نیز فرآیندی پرهزینه و زمان‌بر است و در بسیاری از موارد امکان‌پذیر نیست. بنابراین، توسعه روش‌هایی که بتوانند قابلیت تعمیم‌پذیری مدل‌ها را بهبود بخشند، به یکی از موضوعات مهم در پژوهش‌های اخیر تبدیل شده است [۷]. در این راستا، رویکردهایی نظیر یادگیری انتقالی، تطبیق دامنه و بهره‌گیری از مدل‌های مقاوم در برابر تغییر توزیع داده‌ها به‌عنوان راهکارهایی برای افزایش کارایی مدل‌ها در محیط‌های زمین‌شناسی متفاوت مورد توجه قرار گرفته‌اند.

۱-۵-۶ محدودیت دسترسی به داده‌های واقعی در صنایع نفت و گاز به دلیل

ملاحظات امنیتی و محرمانگی

در صنایع نفت و گاز، دسترسی به داده‌های واقعی عملیاتی همواره با محدودیت‌های جدی مواجه است. بخش قابل‌توجهی از اطلاعات مرتبط با فرآیندهای تولید، انتقال، ذخیره‌سازی و مدیریت دارایی‌ها در این صنایع دارای ماهیت حساس بوده و افشای آن‌ها می‌تواند پیامدهای امنیتی، اقتصادی و حتی ژئوپلیتیکی به‌همراه داشته باشد. با توجه به این حساسیت‌ها، شرکت‌های نفت و گاز معمولاً سیاست‌های سخت‌گیرانه‌ای برای حفاظت از داده‌ها اتخاذ می‌کنند و تنها بخش بسیار محدودی از اطلاعات را در اختیار پژوهشگران و مؤسسات علمی قرار می‌دهند. این محدودیت‌ها منجر به کاهش دسترسی به داده‌های باکیفیت و به‌روز می‌شود و در نتیجه، امکان ارزیابی تجربی، مدل‌سازی دقیق و اعتبارسنجی کاربردی بسیاری از روش‌های پژوهشی را تحت تأثیر قرار می‌دهد. در چنین شرایطی، پژوهشگران ناچارند از داده‌های مصنوعی، نمونه‌های آزمایشگاهی یا مجموعه داده‌های محدود استفاده کنند که ممکن است نمایانگر پیچیدگی‌ها و پویایی‌های واقعی صنعت نباشند.

۱-۶ اهداف رساله

اهداف اصلی این پژوهش عبارت‌اند از:

- امکان‌سنجی توسعه چارچوبی کارآمد برای تولید دیتاست چندوجهی مصنوعی با ترکیب داده‌های چاه‌پیمایی یک میدان و تصاویر مغزه از میدانی دیگر: با توجه به محدودیت دسترسی همزمان به داده‌ها با مدالیته‌های مختلف از یک میدان خاص، این بخش به بررسی امکان

توسعه یک چارچوب تولید داده مصنوعی می‌پردازد که در آن داده‌های چاه‌پیمایی یک میدان با تصاویر مغزه از میدانی دیگر ترکیب می‌شوند. هدف، ایجاد یک دیتاست چندوجهی مصنوعی اما معنادار برای آموزش مدل‌های یادگیری عمیق است تا از طریق بهره‌گیری همزمان از اطلاعات مکمل موجود در هر مدالیت، ظرفیت مدل‌ها در استخراج ویژگی‌های متمایز و در نتیجه بهبود دقت طبقه‌بندی لیتولوژی ارتقا یابد.

- **بررسی کارایی رویکردهای مبتنی بر تطبیق دامنه و تعمیم دامنه در انتقال دانش میان میادین مختلف به منظور طبقه‌بندی لیتولوژی:**

به دلیل تفاوت‌های زمین‌شناسی میان میادین مختلف، مدل‌هایی که بر اساس داده‌های یک میدان آموزش داده شده‌اند معمولاً در میادین دیگر عملکرد ضعیف‌تری دارند. در این راستا، این پژوهش به ارزیابی روش‌های تطبیق دامنه و تعمیم دامنه می‌پردازد تا امکان انتقال دانش میان میادین مختلف بررسی شود. هدف، ارزیابی میزان توانایی این رویکردها در کاهش اثر اختلاف توزیع داده‌ها و بهبود تعمیم‌پذیری مدل‌ها می‌باشد.

- **ارزیابی قابلیت روش‌های مبتنی بر طبقه‌بندی مجموعه‌باز در شناسایی نمونه‌های متعلق به کلاس‌های لیتولوژی ناشناخته و تفکیک آن‌ها از کلاس‌های شناخته‌شده در طی فرآیند آموزش:** در کاربردهای واقعی، ممکن است داده‌هایی به مدل ارائه شوند که متعلق به هیچ‌یک از کلاس‌های تعریف‌شده در مرحله آموزش نباشند. در این رساله، کارایی روش‌های طبقه‌بندی مجموعه‌باز در تشخیص چنین نمونه‌هایی بررسی می‌شود. هدف آن است که مدل بتواند علاوه بر طبقه‌بندی صحیح کلاس‌های شناخته‌شده، نمونه‌های ناشناخته را نیز شناسایی کرده و از انتساب نادرست آن‌ها به کلاس‌های موجود جلوگیری کند.

- **بررسی میزان کارایی رویکردهای یادگیری مشارکتی در حفظ محرمانگی داده‌ها و در عین حال ارتقای دقت مدل‌های طبقه‌بندی لیتولوژی در همکاری‌های بین‌سازمانی و میادین مشترک:**

با توجه به حساسیت و محرمانگی داده‌های اکتشاف و توسعه مخازن، اشتراک‌گذاری مستقیم داده‌ها میان سازمان‌ها و شرکت‌ها با محدودیت‌های جدی مواجه است. در این راستا، قابلیت استفاده از روش‌های یادگیری مشارکتی برای آموزش مدل‌های طبقه‌بندی لیتولوژی بدون تبادل مستقیم داده‌ها مورد بررسی قرار می‌گیرد. هدف، ارزیابی این موضوع است که آیا می‌توان ضمن

حفظ محرمانگی داده‌ها، از مزایای تجمیع دانش حاصل از داده‌های متعلق به سازمان‌های مختلف بهره گرفت و از این طریق عملکرد و قابلیت تعمیم مدل‌ها را در بستر همکاری‌های بین‌سازمانی یا در میادین مشترک بهبود داد.

۷-۱ سوالات پژوهش

پژوهش حاضر می‌کوشد برای پرسش‌های زیر پاسخ‌هایی مناسب و مستدل ارائه نماید.

- آیا می‌توان با ترکیب داده‌های چاه‌پیمایی یک میدان و تصاویر مغزه میدانی دیگر، یک دیتاست چندوجهی مصنوعی کارآمد و باکیفیت تولید کرد؟
- آیا با استفاده از رویکردهای مبتنی بر تطبیق یا تعمیم دامنه می‌توان از داده‌های چاه‌پیمایی، تصاویر مغزه و اطلاعات لیتولوژیکی یک میدان به منظور طبقه‌بندی لیتولوژی در میدانی دیگر استفاده کرد؟
- آیا استفاده از رویکردهای مبتنی بر طبقه‌بندی مجموعه‌باز قادر است نمونه‌های متعلق به کلاس‌های ناشناخته در مرحله آزمون را شناسایی کرده و آن‌ها را به‌صورت مؤثر از نمونه‌های متعلق به کلاس‌های شناخته‌شده تفکیک کند؟
- به‌کارگیری یادگیری مشارکتی تا چه اندازه می‌تواند ضمن حفظ کارایی و دقت مدل، در صیانت از محرمانگی داده‌ها در همکاری‌های بین‌سازمانی و بهره‌برداری از میادین مشترک مؤثر واقع شود؟

فصل دوم

مبانی نظری و پیشینه پژوهش

این فصل مبانی نظری و پیشینه علمی مرتبط با مسئله‌ی تشخیص لیتولوژی را به طور جامع مورد بررسی قرار می‌دهد. هدف از این مطالعه، ایجاد زمینه‌ای مناسب برای آشنایی عمیق‌تر با این مسئله و کمک به درک بهتر جایگاه روش‌های پیشنهادی در بستر تحقیقات موجود است.

ابتدا تعاریف دقیق و طبقه‌بندی‌های علمی در حوزه لیتولوژی و چاه‌پیمایی^۱ ارائه می‌شود تا مبانی مشترکی برای بحث‌های بعدی فراهم گردد. سپس مروری سیستماتیک بر روش‌های مبتنی بر هوش مصنوعی در حوزه تشخیص لیتولوژی در قالب دسته‌بندی‌های منطقی صورت می‌گیرد تا درکی بنیادین از مفاهیم اولیه تا روش‌های پیچیده شکل گیرد.

در ادامه، مقایسه‌ای از کارهای پیشین ارائه خواهد شد تا جایگاه و نوآوری‌های رویکردهای پیشنهادی در این پژوهش مشخص شود. این مرور و بررسی جامع، امکان درک بهتر محدودیت‌ها و فرصت‌های موجود در ادبیات فعلی را فراهم کرده و ضرورت توسعه‌ی رویکردهای جدید را توجیه می‌کند.

۱-۲ مفاهیم و تعاریف اولیه

در این بخش، مبانی نظری و مفاهیم بنیادین مرتبط با لیتولوژی و چاه‌پیمایی مورد بررسی قرار می‌گیرند. هدف از این بخش، ایجاد درکی منسجم و دقیق از مفاهیم کلیدی است که مبانی تحلیل‌ها و تفسیرهای بعدی در پژوهش حاضر را شکل می‌دهند.

۱-۱-۲ تعریف لیتولوژی

لیتولوژی شاخه‌ای از زمین‌شناسی است که به توصیف و شناسایی ویژگی‌های فیزیکی، بافتی و ترکیبی سنگ‌ها اختصاص دارد. این مفهوم به‌طور خاص به خصوصیات قابل مشاهده و قابل اندازه‌گیری سنگ‌ها مانند ترکیب کانی‌شناسی، اندازه و شکل دانه‌ها، رنگ، ساختار، بافت و نحوه سیمانی شدن^۲ یا فشردگی^۳ آن‌ها اشاره دارد. در مطالعات زمین‌شناسی، لیتولوژی به عنوان یکی از مهم‌ترین معیارها برای توصیف و طبقه‌بندی سنگ‌ها و همچنین تفسیر شرایط تشکیل و محیط رسوبی آن‌ها مورد استفاده قرار می‌گیرد. از دیدگاه رسوب‌شناسی^۴ و چینه‌شناسی^۵، لیتولوژی بیانگر مجموعه ویژگی‌هایی است که یک واحد

^۱Well Logging

^۲Cementation

^۳Compaction

^۴Sedimentology

^۵Stratigraphy

سنگی را از نظر ترکیب و خصوصیات فیزیکی از واحدهای مجاور متمایز می‌کند. به همین دلیل، تغییرات لیتولوژیکی در توالی‌های سنگی می‌تواند نشان‌دهنده تغییر در شرایط رسوب‌گذاری، منبع رسوبات، انرژی محیطی و یا فرآیندهای ترازشی^۶ باشد. بررسی این تغییرات به زمین‌شناسان کمک می‌کند تا تاریخچه زمین‌شناسی یک منطقه و تحولات محیطی آن را بازسازی کنند.

در مطالعات زمین‌شناسی کاربردی، به‌ویژه در اکتشاف منابع طبیعی مانند نفت، گاز، آب‌های زیرزمینی و ذخایر معدنی، شناخت لیتولوژی نقش اساسی دارد. ویژگی‌های لیتولوژیکی سنگ‌ها تأثیر مستقیم بر خصوصیات مهمی مانند تخلخل، تراوایی، مقاومت مکانیکی و رفتار هیدروژئولوژیکی آن‌ها دارند. بنابراین تحلیل دقیق لیتولوژی نه تنها در توصیف واحدهای سنگی بلکه در ارزیابی پتانسیل مخزنی و مهندسی سنگ‌ها نیز اهمیت ویژه‌ای دارد.

به طور کلی، لیتولوژی به عنوان یکی از بنیادی‌ترین مفاهیم در زمین‌شناسی، چارچوبی نظام‌مند برای توصیف علمی سنگ‌ها فراهم می‌کند و مبنایی برای بسیاری از شاخه‌های علوم زمین از جمله چینه‌شناسی، رسوب‌شناسی، زمین‌شناسی مهندسی^۷ و زمین‌شناسی اقتصادی به شمار می‌آید.

با این حال، در مطالعات مخازن هیدروکربنی، شناخت لیتولوژی صرفاً به توصیف ترکیب کانی‌شناسی و ویژگی‌های بافتی سنگ‌ها محدود نمی‌شود، بلکه درک رفتار فیزیکی سنگ‌ها در برابر سیالات، جریان، میدان‌های الکتریکی و امواج الاستیک نیز از اهمیت بنیادی برخوردار است. این رفتارها که در قالب مجموعه‌ای از ویژگی‌های موسوم به خواص پتروفیزیکی بیان می‌شوند، پیوندی اساسی میان خصوصیات ذاتی سنگ و پاسخ آن در داده‌های اندازه‌گیری‌شده ژئوفیزیکی (به‌ویژه نمودارهای چاه‌پیمایی) برقرار می‌کنند. در واقع، بسیاری از روش‌های نوین تحلیل مخزن و رویکردهای داده‌محور، از جمله کاربرد الگوریتم‌های هوش مصنوعی در تفسیر داده‌های زیرسطحی، بر پایه همین ارتباط میان ویژگی‌های پتروفیزیکی و پاسخ ثبت‌شده در ابزارهای اندازه‌گیری استوار هستند. از این‌رو، پیش از پرداختن به معرفی و بررسی لیتولوژی‌های شاخص در مخازن هیدروکربنی، ضروری است مهم‌ترین خواص پتروفیزیکی سنگ‌ها و نقش آن‌ها در توصیف و تفسیر رفتار سنگ-سیال مورد بررسی قرار گیرد؛ مفاهیمی که شناخت دقیق آن‌ها بستر لازم را برای درک تفاوت‌های لیتولوژیکی و تحلیل داده‌های چاه‌پیمایی فراهم می‌سازد.

^۶Diagenesis Process

^۷Engineering Geology

۲-۱-۲ خواص پتروفیزیکی سنگ‌ها

ویژگی‌های پتروفیزیکی بیانگر خصوصیات فیزیکی و رفتار سنگ‌های مخزنی در برابر سیالات، جریان، میدان‌های الکتریکی و امواج الاستیک هستند. این ویژگی‌ها نقش اساسی در ارزیابی کیفیت مخزن، تعیین ظرفیت ذخیره‌سازی سیالات و پیش‌بینی رفتار تولیدی مخازن هیدروکربنی ایفا می‌کنند. مطالعه این خصوصیات همچنین مبنای اصلی تفسیر داده‌های چاه‌پیمایی و توسعه مدل‌های زمین‌شناسی و ژئوفیزیکی مخزن محسوب می‌شود. از مهم‌ترین ویژگی‌های پتروفیزیکی که در مطالعات مخزنی مورد بررسی قرار می‌گیرند می‌توان به تخلخل، تراوایی، اشباع سیال، مقاومت الکتریکی و سرعت انتشار امواج لرزه‌ای اشاره کرد. شناخت دقیق این ویژگی‌ها برای تحلیل لیتولوژی و ارزیابی کیفیت مخزن ضروری است.

• **تخلخل:** تخلخل یکی از بنیادی‌ترین ویژگی‌های پتروفیزیکی سنگ‌ها است که ظرفیت ذخیره‌سازی سیالات در محیط متخلخل را تعیین می‌کند. این پارامتر به صورت نسبت حجم فضاهای خالی موجود در سنگ به حجم کل آن تعریف می‌شود:

$$\phi = \frac{V_b}{V_p} \quad (۱-۲)$$

که در آن V_p حجم فضاهای خالی و V_b حجم کل سنگ است. تخلخل معمولاً به صورت درصد بیان می‌شود و می‌تواند تحت تأثیر عوامل مختلفی نظیر بافت رسوبی، اندازه دانه‌ها، میزان سیمانی‌شدن، فشردگی و فرآیندهای دیاژنتیکی قرار گیرد. به طور کلی تخلخل به دو نوع تخلخل اولیه و ثانویه تقسیم می‌شود. تخلخل اولیه در زمان رسوب‌گذاری تشکیل می‌شود و عمدتاً در سنگ‌های آواری مانند ماسه‌سنگ‌ها مشاهده می‌شود. در مقابل، تخلخل ثانویه در اثر فرآیندهای پس از رسوب‌گذاری مانند انحلال، شکستگی یا دولومیتی شدن ایجاد می‌شود و در بسیاری از مخازن کربناته اهمیت ویژه‌ای دارد.

در مطالعات چاه‌پیمایی، تخلخل با استفاده از چندین نوع نمودار تخمین زده می‌شود. لاگ چگالی (Density Log) با اندازه‌گیری چگالی توده‌ای سنگ، امکان محاسبه تخلخل را فراهم می‌کند، در حالی که لاگ نوترون (Neutron Log) حساس به میزان هیدروژن موجود در سیالات منفذی است و به طور غیرمستقیم تخلخل را نشان می‌دهد. همچنین لاگ صوتی (Sonic Log) با اندازه‌گیری زمان عبور موج فشاری از سنگ، اطلاعاتی درباره ساختار متخلخل ارائه می‌دهد. ترکیب این لاگ‌ها

یکی از روش‌های متداول برای برآورد دقیق‌تر تخلخل در مخازن هیدروکربنی است.

- **تراوایی:** تراوایی بیانگر توانایی سنگ در عبور دادن سیالات از میان شبکه منافذ متصل است و یکی از مهم‌ترین شاخص‌های تعیین‌کننده قابلیت تولید مخزن به شمار می‌رود. برخلاف تخلخل که صرفاً میزان فضای خالی را نشان می‌دهد، تراوایی میزان پیوستگی و قابلیت جریان یافتن سیالات در این فضاها را مشخص می‌کند. تراوایی بر اساس قانون دارسی تعریف می‌شود که جریان سیال در محیط متخلخل را توصیف می‌کند:

$$k = \frac{Q\mu L}{A\Delta P} \quad (2-2)$$

- **اشباع هیدروکربنی:**

اشباع سیال بیانگر نسبت حجمی هر سیال موجود در فضای متخلخل سنگ است. در مخازن هیدروکربنی، معمولاً سه نوع سیال شامل آب، نفت و گاز در منافذ سنگ حضور دارند. اشباع هیدروکربنی به صورت زیر تعریف می‌شود:

$$S_h = 1 - S_w \quad (3-2)$$

که در آن S_w اشباع آب است. این پارامتر یکی از مهم‌ترین شاخص‌ها در ارزیابی اقتصادی مخازن محسوب می‌شود زیرا تعیین می‌کند چه بخشی از فضای متخلخل سنگ توسط هیدروکربن‌ها اشغال شده است. محاسبه اشباع آب و در نتیجه اشباع هیدروکربنی معمولاً بر اساس داده‌های لاگ مقاومت ویژه انجام می‌شود. در سنگ‌های تمیز و فاقد کانی‌های رسی، رابطه بین مقاومت الکتریکی، تخلخل و اشباع آب با استفاده از قانون آرچی (Archie's Law) بیان می‌شود. این قانون نشان می‌دهد که افزایش اشباع آب باعث کاهش مقاومت الکتریکی سنگ می‌شود زیرا آب سازندی معمولاً دارای املاح محلول و در نتیجه رسانایی الکتریکی بالایی است.

در سنگ‌های حاوی رس، حضور کانی‌های رسی می‌تواند بر اندازه‌گیری مقاومت الکتریکی تأثیر بگذارد و باعث خطا در محاسبه اشباع شود. به همین دلیل در چنین شرایطی از مدل‌های اصلاح‌شده مانند مدل سیمان‌دو یا دوآبی استفاده می‌شود.

- **مقاومت الکتریکی:**

مقاومت الکتریکی سنگ نشان‌دهنده میزان مخالفت آن با عبور جریان الکتریکی است و یکی از مهم‌ترین پارامترها در تفسیر داده‌های چاه‌پیمایی به شمار می‌رود. در بیشتر سنگ‌های مخزنی، جریان الکتریکی عمدتاً از طریق سیالات موجود در منافذ عبور می‌کند زیرا ماتریس سنگ معمولاً رسانایی بسیار کمی دارد.

مقدار مقاومت الکتریکی سنگ به عوامل مختلفی مانند میزان اشباع آب، شوری آب سازندی، تخلخل و نوع لیتولوژی وابسته است. در سنگ‌های اشباع از آب شور، مقاومت الکتریکی معمولاً پایین است، در حالی که حضور نفت یا گاز که رسانایی بسیار کمی دارند باعث افزایش قابل توجه مقاومت الکتریکی می‌شود.

نمودارهای Resistivity Log با اندازه‌گیری مقاومت الکتریکی سازند در اطراف چاه، اطلاعات ارزشمندی درباره نوع سیال موجود در منافذ ارائه می‌دهند. به همین دلیل این لاگ‌ها نقش اساسی در تشخیص زون‌های هیدروکربنی و تفکیک آن‌ها از زون‌های آب‌دار دارند.

• سرعت امواج لرزه‌ای:

سرعت انتشار امواج لرزه‌ای یکی دیگر از ویژگی‌های مهم پتروفیزیکی سنگ‌ها است که به خصوص در مطالعات ژئوفیزیکی و تفسیر داده‌های لرزه‌ای کاربرد گسترده‌ای دارد. این ویژگی نشان می‌دهد که امواج الاستیک با چه سرعتی در سنگ منتشر می‌شوند و به خواص مکانیکی و فیزیکی سنگ وابسته است. سرعت موج فشاری (V_p) به طور کلی به مدول‌های الاستیک و چگالی سنگ وابسته است و به صورت زیر بیان می‌شود:

$$V_p = \sqrt{\frac{K + \frac{4}{3}G}{\rho}} \quad (۴-۲)$$

که در آن K مدول حجم G مدول برشی و ρ چگالی سنگ است. سرعت امواج در سنگ‌های متراکم و کم‌تخلخل معمولاً بیشتر از سنگ‌های متخلخل است. همچنین نوع سیال موجود در منافذ می‌تواند بر سرعت امواج تأثیر بگذارد؛ به عنوان مثال حضور گاز معمولاً باعث کاهش قابل توجه سرعت موج فشاری می‌شود. در چاه‌پیمایی، سرعت امواج با استفاده از لاگ صوتی^۸ اندازه‌گیری می‌شود. این داده‌ها علاوه بر تخمین تخلخل، در تطابق داده‌های چاه با داده‌های لرزه‌ای و مدل‌سازی زمین‌شناسی مخزن نیز کاربرد دارند.

^۸Sonic Log

۳-۱-۲ تعریف چاه پیمایی

چاه پیمایی یا نمودارگیری از چاه، یکی از ابزارهای کلیدی در مطالعات زیرسطحی و ارزیابی مخازن هیدروکربنی به شمار می‌آید. این روش مجموعه‌ای از عملیات اندازه‌گیری و ثبت پیوسته ویژگی‌های فیزیکی، شیمیایی و الکتریکی سازندهای پیرامون چاه را در امتداد عمق چاه دربر می‌گیرد. هدف اصلی از چاه پیمایی، تعیین خصوصیات سنگ و سیال، شناسایی لیتولوژی، ارزیابی کیفیت مخزن و تشخیص زون‌های تولیدی یا اشباع از هیدروکربن است.

۴-۱-۲ معرفی لیتولوژی‌های شاخص در مخازن هیدروکربنی

پوسته زمین از تنوع قابل توجهی در ترکیب کانی‌شناسی، ساختار و بافت برخوردار است که منجر به شناسایی و طبقه‌بندی لیتولوژی‌های گوناگون در مطالعات زمین‌شناسی می‌شود. با این وجود، در کاربردهای عملی به‌ویژه در اکتشافات هیدروکربنی، برخی لیتولوژی‌ها از فراوانی و اهمیت ویژه‌ای برخوردارند. شناخت دقیق این لیتولوژی‌ها برای تفسیر صحیح داده‌های زمین‌شناسی و ژئوفیزیکی، خصوصاً در تحلیل داده‌های چاه پیمایی، امری حیاتی است.

تمایز لیتولوژی‌ها در مطالعات مخزنی و تحلیل داده‌های چاه پیمایی نقشی اساسی در شناخت ساختارهای زیرسطحی زمین ایفا می‌کند، زیرا هر نوع سنگ با ویژگی‌های فیزیکی و پتروفیزیکی منحصر به فرد خود بیانگر شرایط زمین‌شناسی متفاوتی است. درک این تفاوت‌ها زمینه‌ساز بازسازی دقیق‌تر توزیع عمقی لایه‌ها بوده و به‌طور مستقیم در شناسایی نواحی مستعد تجمع هیدروکربن و تعیین موقعیت مخازن زیرزمینی مؤثر است.

این بخش به معرفی و بررسی لیتولوژی‌های شاخص شناسایی شده در مطالعات مخزنی اختصاص دارد. تمرکز بر لیتولوژی‌هایی است که بیشترین کاربرد را در تحلیل داده‌های چاه پیمایی و شناسایی مخازن هیدروکربنی دارند. هر یک از این لیتولوژی‌ها از منظر ترکیب کانی‌شناسی، ویژگی‌های بافتی، محیط‌های رسوب‌گذاری و اهمیت در مطالعات مخزنی و تفسیر داده‌های چاه، مورد تجزیه و تحلیل قرار خواهند گرفت.

• ماسه سنگ:

ماسه سنگ^۹ یکی از مهم‌ترین و فراوان‌ترین سنگ‌های رسوبی آواری است که از تجمع و سیمانی شدن ذرات ماسه با اندازه دانه‌ای در حدود ۰/۰۶۲۵ تا ۲ میلی‌متر تشکیل می‌شود. این سنگ‌ها

^۹Sandstone

عمدتاً از دانه‌های کوارتز، فلدسپار و قطعات سنگی تشکیل شده‌اند و نسبت این اجزا نقش مهمی در تعیین ویژگی‌های فیزیکی و پتروفیزیکی آن‌ها دارد.

از نظر کانی‌شناسی، کوارتز معمولاً فراوان‌ترین کانی موجود در ماسه‌سنگ‌ها است، زیرا مقاومت بالایی در برابر هوازدگی شیمیایی و فیزیکی دارد. بر اساس ترکیب کانی‌شناسی و نسبت اجزای تشکیل‌دهنده، ماسه‌سنگ‌ها به انواع مختلفی مانند کوارتز آرنیت، آرکوز و لیت‌آرنیت طبقه‌بندی می‌شوند. از نظر بافتی، ویژگی‌هایی مانند اندازه دانه‌ها، درجه جورشدگی، میزان گردشدگی و نوع سیمان از عوامل مهم در تعیین خصوصیات ماسه‌سنگ‌ها محسوب می‌شوند.

ماسه‌سنگ‌ها در محیط‌های رسوبی متنوعی از جمله محیط‌های رودخانه‌ای، دلتایی، ساحلی، دریایی کم‌عمق و همچنین محیط‌های بادی تشکیل می‌شوند. از دیدگاه مخزنی، این سنگ‌ها معمولاً دارای تخلخل و تراوایی نسبتاً بالایی هستند و به همین دلیل یکی از مهم‌ترین سنگ‌های مخزن برای ذخیره و انتقال سیالات زیرسطحی مانند نفت، گاز و آب‌های زیرزمینی به شمار می‌روند. در تفسیر داده‌های چاه‌پیمایی نیز ماسه‌سنگ‌ها معمولاً مقادیر نسبتاً پایینی در نمودار گاما نشان می‌دهند و رفتار مشخصی در نمودارهای چگالی و نوترون دارند.

• سنگ آهک:

سنگ آهک^{۱۰} یکی از مهم‌ترین سنگ‌های رسوبی کربناته است که عمدتاً از کانی کلسیت (CaCO_3) تشکیل شده است. این سنگ‌ها معمولاً در محیط‌های دریایی کم‌عمق و گرم تشکیل می‌شوند و در بسیاری از موارد منشاء زیستی دارند، به این معنا که از تجمع بقایای اسکلت موجودات دریایی مانند مرجان‌ها، جلبک‌ها و پوسته‌های آهکی تشکیل شده‌اند.

سنگ‌های آهکی دارای تنوع بافتی زیادی هستند و می‌توانند به صورت دانه‌ای، بلورین یا زیستی دیده شوند. فرآیندهای دیاژنتیکی مانند سیمانی شدن، انحلال و دولومیتی شدن می‌توانند ویژگی‌های اولیه این سنگ‌ها را تغییر دهند و بر خصوصیات مخزنی آن‌ها تأثیر بگذارند.

از دیدگاه مخزنی، سنگ‌های آهکی می‌توانند تخلخل و تراوایی قابل توجهی داشته باشند، به‌ویژه زمانی که فرآیندهای دیاژنتیکی موجب ایجاد حفرات ثانویه در آن‌ها شده باشد. در نمودارهای چاه‌پیمایی، این سنگ‌ها معمولاً مقادیر پایین‌تری در نمودار گاما نسبت به شیل‌ها نشان می‌دهند و رفتار خاصی در نمودارهای چگالی و نوترون دارند که امکان تشخیص آن‌ها را فراهم می‌کند.

¹⁰Limestone

• دولومیت:

دولومیت^{۱۱} نوعی سنگ رسوبی کربناته است که عمدتاً از کانی دولومیت با ترکیب شیمیایی $(CaMg(CO_3)_2)$ تشکیل شده است. این سنگ‌ها اغلب در نتیجه فرآیندی به نام دولومیتی شدن ایجاد می‌شوند که طی آن بخشی از کلسیت موجود در سنگ آهک توسط منیزیم جایگزین می‌شود. فرآیند دولومیتی شدن می‌تواند تغییرات قابل توجهی در ساختار و ویژگی‌های پتروفیزیکی سنگ ایجاد کند. در بسیاری از موارد، این فرآیند باعث افزایش تخلخل سنگ می‌شود و در نتیجه می‌تواند نقش مهمی در ایجاد مخازن هیدروکربنی ایفا کند. به همین دلیل، دولومیت‌ها در بسیاری از مخازن نفت و گاز جهان به عنوان سنگ مخزن مهم شناخته می‌شوند.

از نظر پاسخ ژئوفیزیکی، دولومیت‌ها رفتار متفاوتی نسبت به سنگ‌های آهکی در برخی نمودارهای چاه‌پیمایی از جمله نمودار چگالی نشان می‌دهند و این تفاوت‌ها می‌تواند در تشخیص آن‌ها مورد استفاده قرار گیرد.

• شیل:

شیل^{۱۲} یکی از رایج‌ترین سنگ‌های رسوبی دانه‌ریز است که عمدتاً از ذرات بسیار ریز رسی و سیلتی تشکیل شده است. اندازه دانه‌ها در این سنگ‌ها معمولاً کمتر از 0.0625 میلی‌متر است و همین ویژگی باعث ایجاد ساختار لایه‌ای یا ورقه‌ای در آن‌ها می‌شود. شیل‌ها اغلب دارای رنگ‌های متنوعی از جمله خاکستری، سیاه، قهوه‌ای و سبز هستند که این تفاوت رنگ معمولاً به ترکیب کانی‌شناسی و میزان مواد آلی موجود در آن‌ها مربوط می‌شود.

ترکیب کانی‌شناسی شیل‌ها غالباً شامل کانی‌های رسی مانند ایلیت، کائولینیت و اسمکتیت است، هرچند ممکن است مقادیری از کوارتز، فلدسپار و مواد آلی نیز در آن‌ها وجود داشته باشد. این سنگ‌ها معمولاً در محیط‌های رسوبی کم‌انرژی مانند دریاچه‌های عمیق، تالاب‌ها، دریاچه‌ها و محیط‌های دلتایی تشکیل می‌شوند، جایی که ذرات ریز فرصت ته‌نشینی پیدا می‌کنند.

از نظر مخزنی، شیل‌ها معمولاً دارای تراوایی بسیار پایین هستند و به همین دلیل اغلب به عنوان سنگ پوش^{۱۳} در سیستم‌های نفتی عمل می‌کنند. در داده‌های چاه‌پیمایی، شیل‌ها معمولاً مقادیر بالایی در نمودار گاما دارند، زیرا کانی‌های رسی موجود در آن‌ها حاوی عناصر رادیواکتیو طبیعی

¹¹ Dolomite

¹² Shale

¹³ Cap Rock

مانند پتاسیم هستند.

• انیدریت:

انیدریت^{۱۴} یکی از سنگ‌های تبخیری است که از کانی سولفات کلسیم بدون آب (CaSO_4) تشکیل شده است. این سنگ‌ها معمولاً در محیط‌های تبخیری مانند حوضه‌های بسته دریایی یا دریاچه‌های شور تشکیل می‌شوند، جایی که تبخیر شدید آب باعث رسوب‌گذاری کانی‌های تبخیری می‌شود. انیدریت‌ها معمولاً دارای بافت بلورین و رنگ‌های خاکستری، سفید یا متمایل به آبی هستند. این سنگ‌ها اغلب در کنار سایر سنگ‌های تبخیری مانند ژپس و هالیت یافت می‌شوند و می‌توانند نقش مهمی در سیستم‌های نفتی به عنوان سنگ پوش ایفا کنند.

در نمودارهای چاه‌پیمایی، انیدریت‌ها معمولاً دارای چگالی نسبتاً بالا و مقادیر بسیار پایین در نمودار گاما هستند. این ویژگی‌ها می‌تواند در تفکیک آن‌ها از سایر لیتولوژی‌ها مورد استفاده قرار گیرد.

• مارل:

مارل^{۱۵} نوعی سنگ رسوبی است که از ترکیبی از مواد آهکی و رس تشکیل شده است. این سنگ‌ها معمولاً دارای درصد قابل توجهی از کربنات کلسیم به همراه کانی‌های رسی هستند و از نظر ویژگی‌های فیزیکی و شیمیایی حالتی بین سنگ آهک و شیل دارند.

مارل‌ها اغلب در محیط‌های دریایی آرام و کم‌انرژی تشکیل می‌شوند و می‌توانند نشان‌دهنده تغییرات تدریجی در شرایط رسوب‌گذاری باشند. این سنگ‌ها معمولاً دارای رنگ‌های خاکستری، سبز یا قهوه‌ای هستند و بافت نسبتاً نرم و شکننده‌ای دارند.

از نظر مخزنی، مارل‌ها معمولاً دارای تخلخل و تراوایی پایین‌تری نسبت به ماسه‌سنگ‌ها و برخی سنگ‌های کربناته هستند، اما حضور آن‌ها در توالی‌های رسوبی می‌تواند اطلاعات مهمی درباره شرایط رسوب‌گذاری و تغییرات محیطی ارائه دهد. در داده‌های چاه‌پیمایی، مارل‌ها معمولاً پاسخ‌هایی بین سنگ آهک و شیل نشان می‌دهند، زیرا ترکیبی از کانی‌های کربناته و رسی در ساختار آن‌ها وجود دارد.

¹⁴ Anhydrite

¹⁵ Marl

۲-۲ پیش‌بینی لیتولوژی با استفاده از نمودارهای چاه‌پیمایی

این بخش مروری جامع بر مهم‌ترین پژوهش‌های انجام‌شده در زمینه پیش‌بینی لیتولوژی با استفاده از نمودارهای چاه‌پیمایی و با بهره‌گیری از تکنیک‌های هوش مصنوعی ارائه می‌دهد. به‌عنوان نمونه، [8] با استفاده از جنگل تصادفی و مدل‌های یادگیری عمیق (CNN و ResNet)، لیتولوژی‌ها را بر پایه‌ی لاگ‌های پرتو گاما، چگالی و مقاومت ویژه مربوط به ۲۲ چاه در جنوب سیچوان چین پیش‌بینی کرده است. همچنین [9]، چارچوب پیشرفته‌ای برای طبقه‌بندی لیتولوژی معرفی می‌کند که با ادغام مهندسی ویژگی مبتنی بر فیزیک، روش‌های توازن‌سازی SMOTE-NearMiss و مدل‌های نوین یادگیری عمیق از جمله Deep-Insight، GrowNet توسعه یافته است.

لاگ‌های چاه ابزارهای اساسی در مطالعات زیرسطحی هستند. با این حال، آن‌ها اغلب به دلیل چالش‌های عملیاتی مختلفی دارای مقادیر مفقود می‌باشند. این مسئله می‌تواند استفاده‌ی کاربردی از لاگ‌های چاه را در کاربردهای واقعی، مانند شناسایی لیتولوژی، با مشکل مواجه کند. پژوهش [10]، چارچوب FlexLogNet را معرفی می‌کند. این چارچوب یک مدل یادگیری عمیق می‌باشد که به‌طور ویژه برای تکمیل لاگ‌های چاه طراحی شده است. این رویکرد از معماری ترکیبی بهره می‌برد که شامل یک شبکه عصبی گراف ناهمگن به همراه یک شبکه عصبی کاملاً متصل است. این تلفیق به مدل اجازه می‌دهد انواع گوناگون لاگ‌های مفقود را به‌صورت انعطاف‌پذیر پیش‌بینی کند و راهکاری نویدبخش برای مدیریت داده‌های ناقص لاگ‌ها ارائه دهد.

در مطالعه دیگری [11]، یک روش چندمتغیره برای برآورد داده‌های مفقود لاگ‌های چاه بر پایه‌ی چارچوب MICE با استفاده از یادگیری ماشینی ارائه شده است. این پژوهش نشان می‌دهد که پیش‌بینی زنجیره‌ای و تکرارشونده با استفاده از درخت‌های تقویت گرادیانی می‌تواند بازسازی مقاوم مقادیر مفقود را در داده‌های پیچیده و پراکنده فراهم کند. این رویکرد عملکردی بهتری از روش‌های تک‌هدفه سنتی دارد.

ناهمگنی ذاتی لایه‌های زمین‌شناسی در میدان موجب عدم توازن طبیعی در مجموعه داده‌های لیتولوژی می‌شود. مطالعات مختلفی برای کاهش افت عملکرد مدل‌ها در اثر این عدم توازن انجام شده است. مقاله [12] به مقابله با عدم توازن داده در شناسایی لیتولوژی پرداخته و بازنمایی^{۱۶} لایه‌های نازک و کلاس‌های کم‌نمونه را بهبود می‌بخشد. علاوه بر این، یک شبکه‌ی کانولوشنی گراف با سازوکار توجه^{۱۷} نیز به کار

¹⁶Representation

¹⁷Attention

گرفته شده که بر روی نمونه‌های برجسب‌دار و بدون برجسب آموزش می‌بیند. همچنین [13]، مسئله‌ی عدم‌توازن چندکلاسه را با استفاده از (ECOC) ^{۱۸} و یادگیری حساس به هزینه ^{۱۹} در یک مجموعه‌ی ناهمگن مورد بررسی قرار می‌دهد. این روش با تبدیل مسئله‌ی اصلی به مجموعه‌ای از زیرمسائل دودویی متوازن، به‌طور مؤثر خطاهای طبقه‌بندی در کلاس‌های اقلیت را کاهش می‌دهد. لازم به ذکر است که رویکردهای پیشرو در این حوزه بر افزایش پایداری مدل‌ها از طریق مقابله با برجسب‌های نویزی تأکید دارند [14, 15].

۲-۳ پیش‌بینی لیتولوژی با استفاده از تصاویر مغزه

این بخش به بررسی مهم‌ترین پژوهش‌های ارائه شده در زمینه طبقه‌بندی لیتولوژی با استفاده از تصاویر مغزه می‌پردازد. در سال‌های اخیر، استفاده از تصاویر مغزه به‌عنوان منبعی غنی از اطلاعات بافتی و ساختاری، توجه بسیاری از پژوهشگران را در حوزه پیش‌بینی لیتولوژی به خود جلب کرده است. به‌عنوان نمونه، ژانگ و همکاران [۱۶] یک سامانه هوشمند برای شناسایی لیتولوژی شیل‌های قاره‌ای مبتنی بر تصاویر دیجیتال مغزه و شبکه‌های عصبی کانولوشنی ارائه دادند که با بهره‌گیری از پیش‌پردازش تصویر، متعادل‌سازی داده‌ها و مقایسه معماری‌های مختلف، مدل EfficientNet را به‌عنوان گزینه بهینه معرفی کرده و به دقت قابل‌توجهی در تشخیص چندکلاسه لیتولوژی دست یافتند. در همین راستا، دونگ و همکاران [۱۷] با تمرکز بر محدودیت داده‌های برجسب‌خورده، رویکردی نیمه‌نظارتی را برای طبقه‌بندی لیتولوژی از تصاویر مغزه پیشنهاد کردند که با بهره‌گیری از داده‌های بدون برجسب، توانست عملکرد مدل را بهبود داده و مسئله کمبود داده را تا حدی برطرف سازد. این مطالعات نشان می‌دهند که ترکیب یادگیری عمیق با راهکارهای پیشرفته در مدیریت داده، نقش کلیدی در ارتقای دقت و تعمیم‌پذیری مدل‌های مبتنی بر تصاویر مغزه ایفا می‌کند.

¹⁸Error-correcting Output Code

¹⁹Cost-Sensitive

۴-۲ مروری جامع بر دیتاست‌های عمومی در حوزه‌ی تشخیص لیتولوژی

۱-۴-۲ FORCE 2020

چالش FORCE 2020 [۱۸] یک دیتاست معیار (Benchmark) در حوزه یادگیری ماشین برای علوم زمین است. هدف اصلی این چالش، پیش‌بینی لیتولوژی در امتداد عمق چاه با استفاده از داده‌های لاگ‌های ژئوفیزیکی چاه، لیتواستراتیگرافی NPD^{۲۰} و موقعیت مکانی چاه (X و Y) است. این مسئله بازتابی از شرایط واقعی تفسیر پتروفیزیکی در میدان نفت و گاز بوده که در آن به‌طور صریح با عدم قطعیت‌ها، محدودیت‌ها و داده‌های ناقص یا مفقود مواجه هستیم.

جزئیات داده‌ها

داده‌های ارائه‌شده شامل لاگ‌های چاه‌پیمایی، برچسب لیتولوژی و اطلاعات لیتواستراتیگرافی برای بیش از ۹۰ حلقه چاه فراساحلی^{۲۱} در کشور نروژ است. مجموعه لاگ‌ها شامل منحنی‌های رایج پتروفیزیکی نظیر اشعه گاما^{۲۲} (GR)، مقاومت ویژه، چگالی، نوترون، سونیک، کالیپر و برخی پارامترهای حفاری است. در عین حال، همانند داده‌های واقعی میدان، بخش قابل‌توجهی از لاگ‌ها در بسیاری از اعماق یا کل چاه‌ها موجود نیستند و به‌صورت مقدار گمشده (NaN) ثبت شده‌اند. در این مجموعه داده، تنها متغیرهایی که به‌صورت کامل و بدون داده‌های مفقود در دسترس هستند، اطلاعات مربوط به عمق و اشعه گاما (GR) می‌باشند. بنابراین، مدل‌های ارائه‌شده باید ذاتاً توانایی کار با داده‌های گمشده و ناقص را داشته باشند. شکل ۱-۲ معیار ارزیابی منحصر به فرد این دیتاست را معرفی می‌کند. این ماتریس برای هر خطا در طبقه‌بندی، امتیاز منفی متفاوتی در نظر می‌گیرد.

۲-۴-۲ Southern Sichuan Well Log Lithofacies

این دیتاست [۱۹] شامل داده‌های نمودار چاه از ۲۲ حلقه چاه در ناحیه‌ی جنوب سیچوان چین است که بر اساس آن حدود ۷۰۰۰۰ نمونه‌ی برچسب‌خورده‌ی لیتولوژی استخراج شده‌اند. این مجموعه داده شامل انواع منحنی‌های استاندارد نمودار چاه و برچسب‌های لیتولوژیکی متناظر است و با هدف ایجاد یک

²⁰Norwegian Petroleum Directorate lithostratigraphy

²¹Offshore Well

²²Gamma Ray

	Sand stone	Sand stone /Shale	Shale	Marl	Dolo mite	Lime stone	Chalk	Halite	Anhy drite	Tuff	Coal	Base ment
Sand stone	0	2	3.5	3	3.75	3.5	3.5	4	4	2.5	3.875	3.25
Sand stone /Shale	2	0	2.375	2.75	4	3.75	3.75	3.875	4	3	3.75	3
Shale	3.5	2.375	0	2	3.5	3.5	3.75	4	4	2.75	3.25	3
Marl	3	2.75	2	0	2.5	2	2.25	4	4	3.375	3.75	3.25
Dolo mite	3.75	4	3.5	2.5	0	2.625	2.875	3.75	3.25	3	4	3.625
Lime stone	3.5	3.75	3.5	2	2.625	0	1.375	4	3.75	3.5	4	3.625
Chalk	3.5	3.75	3.75	2.25	2.875	1.375	0	4	3.75	3.125	4	3.75
Halite	4	3.875	4	4	3.75	4	4	0	2.75	3.75	3.75	4
Anhy drite	4	4	4	4	3.25	3.75	3.75	2.75	0	4	4	3.875
Tuff	2.5	3	2.75	3.375	3	3.5	3.125	3.75	4	0	2.5	3.25
Coal	3.875	3.75	3.25	3.75	4	4	4	3.75	4	2.5	0	4
Base ment	3.25	3	3	3.25	3.625	3.625	3.75	4	3.875	3.25	4	0

شکل ۲-۱: ماتریس خطای مجموعه داده FORCE 2020

مرجع قابل اعتماد برای پیش‌بینی لیتولوژی و مدل‌سازی داده‌محور در محیط‌های رسوبی توسعه یافته است. ساختار منظم، تنوع لیتولوژی و پوشش عمقی مناسب باعث شده که این دیتاست به‌عنوان یک منبع ارزشمند برای آموزش، آزمون و مقایسه مدل‌های یادگیری ماشین و یادگیری عمیق در حوزه تفسیر نمودار چاه مورد استفاده قرار گیرد.

۳-۴-۲ Drill Core Image Dataset (DCID)

مجموعه داده Drill Core Image Dataset (DCID) [۲۰] یکی از نخستین و جامع ترین مجموعه داده های عمومی در حوزه شناسایی لیتولوژی بر اساس تصاویر مغزه حفاری است که به منظور ارائه یک معیار استاندارد برای ارزیابی روش های یادگیری عمیق طراحی شده است. این دیتاست شامل تصاویر رنگی RGB با وضوح اولیه 512×512 پیکسل بوده و در دو نسخه اصلی ارائه می شود: نسخه DCID-7 شامل ۷ کلاس لیتولوژی با حدود ۵۰۰۰ تصویر در هر کلاس، و نسخه DCID-35 شامل ۳۵ کلاس با ۱۰۰۰ تصویر برای هر کلاس که امکان ارزیابی در سطوح مختلف پیچیدگی را فراهم می کند. داده ها به صورت استاندارد به نسبت ۸۰ به ۲۰ به مجموعه های آموزش و آزمون تقسیم شده اند و علاوه بر نسخه اصلی، نمونه هایی با وضوح های پایین تر (مانند ۳۲، ۶۴، ۱۲۸ و ۲۵۶ پیکسل) نیز برای بررسی عملکرد مدل ها در شرایط مختلف در دسترس هستند. همچنین، با استفاده از راهبرد Real-World Data Augmentation (RWDA)، انواع اغتشاشات و نویزهای واقع گرایانه به داده ها افزوده شده است تا شرایط عملیاتی واقعی شبیه سازی شود. این ویژگی ها، DCID را به یک مرجع مناسب برای توسعه، آموزش و ارزیابی مدل های یادگیری عمیق در مسائل طبقه بندی لیتولوژی تبدیل کرده است.

۴-۴-۲ خلاصه و مقایسه ی دیتاست های عمومی در حوزه ی تشخیص لیتولوژی

جدول ۱-۲ دیتاست های عمومی معرفی شده را به صورت خلاصه و نظام مند معرفی می کند.

جدول ۱-۲: خلاصه و مقایسه ی دیتاست های عمومی در حوزه ی تشخیص لیتولوژی

مرجع	نوع داده	تعداد کلاس های لیتولوژی	تعداد داده ها	منطقه جغرافیایی	مطالعات مبتنی بر دیتاست	لینک دسترسی
[۱۸]	جدولی	۱۲	آموزش: ۱۲۳۴۳ آزمون: ۱۲۳۴۳	نروژ	[۲۱، ۹، ۲۲] [۲۳، ۲۴، ۲۵]	لینک
[۱۹]	جدولی	نسخه اول: ۴ نسخه دوم: ۹	نسخه اول: ۲۵۸۱۴ نسخه دوم: ≈ 70000	جنوب سیچوان، چین	[۱۹]	لینک
[۲۰]	تصویر	نسخه اول: ۷ نسخه دوم: ۳۵	نسخه اول: ۳۵۰۰۰ نسخه دوم: ۳۵۰۰۰	جنوب استرالیا	[۲۰]	لینک

۵-۲ جمع‌بندی

این بخش به صورت خلاصه به مرور و جمع‌بندی مقالات در قالب جدول ۲-۲ می‌پردازد.

جدول ۲-۲: خلاصه و مقایسه پژوهش‌های صورت گرفته در حوزه تشخیص لیتولوژی

مرجع	سال	نوع داده [لینک دیتاست]	هدف پژوهش	روش پژوهش	نتایج ارزیابی عملکرد
[۲۱]	۲۰۲۵	جدولی [لینک]	تشخیص لیتولوژی	Extra Trees Classifier	دقت = 60.74% ، 83.91% penalty score = -0.4087
[۹]	۲۰۲۴	جدولی [لینک]	تشخیص لیتولوژی	Best Model: GrowNET	دقت = 83% penalty score = -0.4145
[۲۵]	۲۰۲۱	جدولی [لینک]	تشخیص لیتولوژی	XGBoost	دقت $\approx 80\%$ penalty score = $-0.5037, -0.4792$
[۱۶]	۲۰۲۴	تصویر	تشخیص لیتولوژی	CNN-based Models EfficientNet (Best)	$TOP1 \approx 60\%$ $TOP5 \approx 95\%$
[۱۷]	۲۰۲۴	تصویر	تشخیص لیتولوژی	Semi-Supervised Deep Learning	بهبود دقت نسبت به حالت نظارت کامل

فصل سوم

فازبندی رساله

۱-۳ فاز اول: تطبیق دامنه برای کنترل ناهمگنی توزیع داده‌ها در میادین مختلف

با توجه به اینکه مدل‌های یادگیری ماشین در تشخیص لیتولوژی به شدت تحت تأثیر ناهمگنی ساختاری و تفاوت‌های ابزارشناسی میان میادین مختلف قرار می‌گیرند، نخستین گام در این پژوهش تمرکز بر مدیریت این ناهمگنی‌هاست. فاز اول با هدف ایجاد بستری پایدار برای انتقال دانش میان میدان‌های مختلف طراحی شده و تلاش می‌کند اختلاف‌های آماری و مفهومی موجود در داده‌های چاه‌نگاری را تا حد ممکن کاهش دهد. در این راستا، رویکردهای پیشرفته تطبیق و تعمیم دامنه به‌عنوان ابزارهای کلیدی مورد مطالعه و توسعه قرار می‌گیرند.

۱-۱-۳ تطبیق دامنه

در کاربردهای عملی مرتبط با تشخیص لیتولوژی از داده‌های چاه‌نگاری، یکی از چالش‌های بنیادین در به‌کارگیری مدل‌های یادگیری ماشین، اختلاف توزیع داده‌ها میان میادین مختلف هیدروکربوری است. در بسیاری از پروژه‌های صنعتی، داده‌های برداشت‌شده از یک میدان نقش *source domain* را ایفا کرده و مدل‌های آموزش‌دیده بر اساس آنها برای پیش‌بینی لیتولوژی در میادین دیگر، یعنی *target domain*، مورد استفاده قرار می‌گیرند. تغییرات ساختاری و چینه‌شناسی، ناهمگنی‌های مخزنی، تفاوت در شرایط رسوب‌گذاری و همچنین تنوع ابزارها و محیط‌های اندازه‌گیری چاه‌نگاری موجب می‌شود که توزیع داده‌ها میان میدان مبدأ و مقصد دارای عدم‌سازگاری قابل توجهی باشد. این پدیده که در ادبیات علمی با عنوان *domain shift* شناخته می‌شود، در صورت عدم مدیریت، می‌تواند موجب کاهش جدی عملکرد مدل‌ها در میدان مقصد شود.

تطبیق دامنه مجموعه‌ای از رویکردهای یادگیری انتقالی است که به‌منظور کاهش یا حذف اختلاف میان توزیع داده‌های مبدأ و مقصد طراحی شده‌اند. هدف اصلی این دسته از روش‌ها یادگیری یک نمایش مشترک و پایدار از داده‌هاست که در آن، ویژگی‌های استخراج‌شده در هر دو دامنه دارای همپوشانی آماری بیشتری باشند. در چنین شرایطی مدل یادگیری ماشین می‌تواند دانش آموخته‌شده در میدان مبدأ را با تلفات کمتر به میدان مقصد تعمیم دهد. معمولاً این فرایند با بهره‌گیری از روش‌هایی همچون کمینه‌سازی اختلاف توزیع‌ها بر اساس معیارهایی نظیر *Maximum Mean Discrepancy (MMD)*، روش‌های مبتنی بر یادگیری خصمانه و شبکه‌های تفکیک‌کننده دامنه یا *Domain-Adversarial Training* و همچنین

روش‌های مبتنی بر تطبیق ویژگی‌های نهفته از طریق نگاشت‌های غیرخطی انجام می‌گیرد.

در مسئله تشخیص لیتولوژی، تطبیق دامنه نقش مهمی در کاهش اثر تفاوت ابزارهای چاه‌نگاری میان میادین مختلف ایفا می‌کند. اختلاف در نوع ابزار، شرایط فیزیکی چاه، میزان نویز، و تغییرات ژئوفیزیکی منطقه‌ای، همگی سبب ایجاد انحراف در مقیاس، دامنه (amplitude) و حتی رابطه میان ویژگی‌های چاه‌نگاری و لیتولوژی می‌شوند. روش‌های تطبیق دامنه می‌توانند این اختلاف‌ها را از طریق هم‌ترازسازی ویژگی‌ها در فضای نهفته کاهش داده و شرایطی فراهم کنند که مدل بتواند بر مبنای الگوهای زمین‌شناسی مشترک، نه ویژگی‌های سطحی وابسته به محیط، فرایند طبقه‌بندی را انجام دهد.

افزون بر این، در بسیاری از شرایط عملیاتی، داده‌های برچسب‌دار از میدان مقصد وجود ندارد یا بسیار محدود است. به همین دلیل، روش‌های تطبیق دامنه بدون ناظر و نیمه‌ناظر (Unsupervised / Semi-supervised Domain Adaptation) در صنعت نفت کاربرد گسترده‌تری دارند. در این روش‌ها مدل تلاش می‌کند بدون اتکا به برچسب‌های میدان مقصد، ساختار داده‌های آن را فراگرفته و تنظیمات لازم برای هم‌ترازی آماری را انجام دهد. این مسئله خصوصاً با توجه به هزینه بسیار بالای نمونه‌برداری، مغزه‌گیری و تفسیر لیتولوژیکی در میادین جدید، بسیار اهمیت پیدا می‌کند.

۳-۱-۲ تعمیم دامنه

در حالی که تطبیق دامنه به‌طور مشخص بر کاهش اختلاف میان میدان مبدأ و یک میدان مقصد خاص متمرکز است، رویکردهای تعمیم دامنه به مسئله‌ای گسترده‌تر می‌پردازند؛ یعنی چگونه می‌توان مدلی توسعه داد که بدون مشاهده مستقیمی از میدان مقصد، توانایی تعمیم به میادین جدید با شرایط زمین‌شناسی کاملاً متفاوت را داشته باشد. این موضوع در صنعت نفت اهمیت ویژه‌ای دارد، زیرا در بسیاری از پروژه‌ها داده‌های مربوط به میادین مقصد از ابتدا در دسترس نیست و مدل باید از ابتدا برای مواجهه با سناریوهای جدید و ناشناخته آماده باشد.

در تعمیم دامنه، چالش اصلی این است که اختلاف میان توزیع داده‌ها نه‌تنها به صورت بالقوه زیاد است، بلکه قابل اندازه‌گیری دقیق نیز نیست. در چنین شرایطی مدل باید الگوهایی از ویژگی‌های پایدار و مستقل از دامنه را یاد بگیرد. چنین ویژگی‌هایی معمولاً مرتبط با فرآیندهای بنیادین زمین‌شناسی و روابط درونی میان داده‌های چاه‌نگاری و رخساره‌های سنگی هستند. رویکردهای متداول در این زمینه شامل Invariant Feature Learning، روش‌های مبتنی بر تنظیم رگولاریزاسیون برای افزایش تنوع داده‌ها در طی آموزش و نیز روش‌های مبتنی بر شبیه‌سازی دامنه‌های مصنوعی با استفاده از تکنیک‌هایی نظیر

افزایش داده و شبکه‌های مولد می‌باشند.

در بسیاری از میادین، تغییرات محیط رسوبی سبب می‌شود که الگوی پاسخ ابزارهای چاه‌نگاری نسبت به همان لیتولوژی در میدان دیگر متفاوت باشد. رویکردهای تعمیم دامنه با هدف یافتن نمایش‌هایی کار می‌کنند که نسبت به چنین تغییراتی مقاوم بوده و بتوانند رفتار لیتولوژیکی داده‌ها را حتی در صورت مشاهده‌نشدن مستقیم دامنه جدید پیش‌بینی کنند. این موضوع به‌صورت خاص زمانی اهمیت بیشتری می‌یابد که میدان مقصد دارای تغییرات شدید در ساختار رسوبی، شرایط دیاژنزی و یا ویژگی‌های ژئوفیزیکی باشد.

از آنجا که تعمیم دامنه رویکردی آینده‌نگرتر و گسترده‌تر نسبت به تطبیق دامنه به شمار می‌رود، ترکیب این دو روش در مسائل پیچیده مرتبط با تشخیص لیتولوژی معمول است. به‌عنوان مثال، مدل‌های مبتنی بر یادگیری خصمانه که ابتدا برای تطبیق دامنه طراحی شده‌اند، در سال‌های اخیر نسخه‌هایی برای تعمیم دامنه نیز ارائه داده‌اند که می‌توانند ویژگی‌های مشترک میان چندین میدان مبدأ را استخراج کنند و مقاومتی فراتر از یک دامنه خاص داشته باشند.

به‌طور کلی، روش‌های تطبیق و تعمیم دامنه نقش مهمی در افزایش قابلیت اعتماد و پایداری مدل‌های تشخیص لیتولوژی در سناریوهای واقعی صنعت نفت دارند. این رویکردها با استخراج ویژگی‌های پایدار و کم‌حساسیت نسبت به تغییرات محیطی، امکان تعمیم‌پذیری مدل‌ها را فراتر از یک میدان مشخص فراهم می‌کنند. در نتیجه، مدل نه‌تنها توانایی تطابق با میدان مقصد را به‌دست می‌آورد، بلکه برای مواجهه با داده‌های ناشناخته و شرایط زمین‌شناسی متنوع نیز آماده می‌شود. این بنیان نظری و تکنیکی، مسیر را برای مراحل بعدی پژوهش و توسعه مدل نهایی هموار می‌سازد.

۲-۳ فاز دوم: شناسایی و مدیریت کلاس‌های لیتولوژیکی ناشناخته

با بهره‌گیری از رویکردهای طبقه‌بندی مجموعه باز

یکی از چالش‌های کمتر توجه شده اما بسیار اساسی در استفاده از مدل‌های یادگیری ماشین در تشخیص لیتولوژی در میادین مختلف، احتمال وجود کلاس‌های ناشناخته یا Unknown Classes در میدان مقصد است. در شرایط واقعی، ممکن است لیتولوژی‌هایی در میدان جدید وجود داشته باشد که نمونه‌ای از آنها در میدان مبدأ مشاهده نشده است. نبود چنین نمونه‌هایی در داده‌های آموزشی سبب می‌شود مدل در مواجهه با این دسته‌ها دچار اطمینان کاذب شده و آنها را به اشتباه در یکی از کلاس‌های شناخته‌شده

قرار دهد. این مسئله می‌تواند پیامدهای بسیار مهمی در تصمیم‌گیری‌های مهندسی مخزن داشته باشد. وجود کلاس‌های ناشناخته به‌طور مستقیم با تغییرات زمین‌شناسی میان میادین ارتباط دارد. در یک میدان ممکن است رخساره‌هایی از نوع ماسه‌سنگ‌ها یا لایه‌های رسی پایدار مشاهده شود، در حالی که میدان دیگر ممکن است شامل شیل‌های آلی، کربنات‌های انحلال‌یافته، یا رخساره‌های تبخیری باشد که نمونه‌ای از آنها در میدان مبدأ وجود نداشته است. تنوع رخساره‌ها سبب می‌شود که احتمال وجود کلاس‌های جدید در میدان مقصد همیشه قابل توجه باشد. این موضوع ضرورت استفاده از رویکردهای یادگیری مقاوم نسبت به کلاس‌های ناشناخته را آشکار می‌سازد.

۱-۲-۳ طبقه‌بندی مجموعه‌باز

طبقه‌بندی مجموعه‌باز^۱ رویکردی است که به‌طور خاص برای مدیریت کلاس‌های ناشناخته در فاز آزمون طراحی شده است. برخلاف طبقه‌بندی مجموعه‌بسته^۲ که فرض می‌کند تمامی کلاس‌های موجود در داده‌های آزمون در مجموعه آموزشی نیز حضور دارند، طبقه‌بندی مجموعه‌باز این فرض را کنار گذاشته و تلاش می‌کند موارد خارج از توزیع را شناسایی کند. در این رویکرد، مدل باید علاوه بر تمایز میان کلاس‌های شناخته‌شده، توانایی تشخیص نمونه‌هایی را داشته باشد که احتمال تعلق آنها به هیچ‌یک از کلاس‌های آموخته‌شده وجود ندارد.

در زمینه تشخیص لیتولوژی، طبقه‌بندی مجموعه‌باز اهمیت ویژه‌ای دارد، زیرا مدل باید قادر باشد تشخیص دهد که برخی از الگوهای مشاهده‌شده در داده‌های چاه‌نگاری با هیچ‌یک از الگوهای شناخته‌شده در میدان مبدأ سازگار نیستند. برای این منظور، روش‌های متعددی توسعه یافته‌اند. بخشی از این روش‌ها بر اساس برآورد عدم قطعیت در پیش‌بینی عمل می‌کنند و از مدل می‌خواهند که در شرایط عدم اطمینان بالا برچسب «ناشناخته» اختصاص دهد. روش‌های دیگری بر اساس تعریف کران‌های تصمیم^۳ عمل کرده و نمونه‌های خارج از این کران‌ها را به‌عنوان کلاس جدید شناسایی می‌کنند. رویکردهای پیشرفته‌تر از روش‌های مولد بهره می‌گیرند که می‌توانند نمونه‌های مصنوعی از کلاس‌های شناخته‌شده تولید کرده و از این طریق مناطق غیرمجاز در فضای ویژگی را تعریف کنند.

در کاربردهای صنعت نفت، ادغام رویکردهای طبقه‌بندی مجموعه‌باز با روش‌های تطبیق و تعمیم دامنه، چارچوبی کارا برای مدیریت همزمان عدم‌سازگاری توزیع داده‌ها و وجود رخساره‌های ناشناخته

¹Open-set Classification

²Closed-set Classification

³Decision Boundaries

فراهم می‌کند. چنین چارچوبی باعث می‌شود مدل نه‌تنها قادر به تعمیم بهتر به میدان‌های جدید باشد، بلکه در مواجهه با لیتولوژی‌های نوظهور نیز عملکرد قابل اعتمادی داشته باشد. این مسئله سبب کاهش ریسک و افزایش ارزش اطلاعات چاه‌نگاری در مراحل مختلف اکتشاف و توسعه میادین هیدروکربوری می‌شود.

۳-۳ فاز سوم: چارچوب حاکمیت و حفظ محرمانگی داده در

شناسایی و مدیریت مخازن هیدروکربوری مبتنی بر یادگیری

مشارکتی

در فاز سوم این پژوهش، تمرکز اصلی بر شناسایی و تبیین الزامات کلیدی جهت پیاده‌سازی صنعتی سامانه‌های هوشمند در محیط‌های واقعی اکتشاف و توسعه میادین هیدروکربوری است. هرچند این الزامات در ادبیات آکادمیک کمتر مورد توجه قرار گرفته‌اند، اما اجرای موفق و پایدار سامانه‌های مبتنی بر هوش مصنوعی در مقیاس صنعتی، مستلزم درک و اعمال دقیق این ملاحظات است.

در پروژه‌های شناسایی و ارزیابی مخازن هیدروکربوری، داده‌های زیرسطحی نظیر لاگ‌های چاه، اطلاعات لرزه‌ای و داده‌های مغزه، از بالاترین سطح حساسیت و محرمانگی برخوردارند. اشتراک این داده‌ها میان شرکت‌ها، پیمانکاران یا سازمان‌های همکار، عموماً محدود و با ملاحظات حقوقی و امنیتی همراه است. این موضوع که چالش‌هایی انکارناپذیر در مسیر آموزش مدل‌های فراگیر و عمومی ایجاد می‌کند.

برای برطرف‌سازی این محدودیت‌ها، رویکردهای یادگیری مشارکتی [۲۶]، به‌عنوان چارچوبی مقیاس‌پذیر و امن در این پژوهش مورد استفاده قرار می‌گیرد. در این ساختار، به‌جای انتقال مستقیم داده‌ها، تنها به‌روزرسانی‌های وزنی مدل‌ها میان نهادها تبادل می‌شود. بدین ترتیب، هر شرکت می‌تواند مدل خود را به‌صورت محلی بر داده‌های در اختیار آموزش دهد و سپس نتایج آموزش (گرادیان‌ها یا وزن‌ها) را به سرور مرکزی ارسال کند تا در فرآیند همگرایی مدل سراسری شرکت نماید. این رویکرد موجب می‌شود که:

- محرمانگی داده‌ها به‌صورت کامل حفظ گردد و هیچ‌گونه دسترسی مستقیم به داده خام وجود نداشته باشد.

- مدل نهایی، بازتاب‌دهنده ویژگی‌های متنوع داده‌های چندمنبعی باشد و در نتیجه، از تعمیم‌پذیری

بالا در میدان‌های مختلف برخوردار گردد.

- حاکمیت داده^۴، مطابق با قوانین بومی هر کشور یا شرکت، حفظ شود.

به‌کارگیری یادگیری مشارکتی در محیط‌های صنعتی همچون میادین مشترک نفتی، به سازمان‌ها این امکان را می‌دهد که ضمن حفظ استقلال داده‌ای، از هم‌افزایی دانش و اطلاعات بهره‌مند شوند. در این پروژه، ساختار کلی ارتباط میان سرور مرکزی و نودهای شرکت‌کننده طراحی و ارزیابی شده و ملاحظات مربوط به ساختار شبکه، تأخیر در تبادل گام‌های گرادیان و همگام‌سازی مدل‌ها برای شرایط واقعی بررسی می‌گردد.

۴-۳ فاز چهارم: تولید مجموعه داده مصنوعی با استفاده از

مدل‌های انتشار

فاز چهارم این پژوهش، به طراحی و توسعه یک چارچوب جامع برای تولید مجموعه داده چندوجهی مصنوعی در مقیاس میدان نفتی اختصاص دارد. هدف اصلی در این بخش، ایجاد توانایی تولید تصاویر مصنوعی مغزه برای میدانی است که تنها داده‌های چاه‌پیمایی آن در دسترس بوده و فاقد هرگونه تصویر مغزه واقعی است. به بیان دیگر، این فاز با بهره‌گیری از تصاویر مغزه موجود متعلق به یک میدان دیگر و همچنین داده‌های چاه‌پیمایی میدان مورد مطالعه، به ایجاد یک دیتاست چندوجهی^۵ پرداخته که شامل هر دو طیف داده مبتنی بر چاه‌پیمایی و داده‌های تصویری مغزه برای یک میدان واحد است. این رویکرد ضمن حل اساسی مشکل کمبود داده تصویری در بسیاری از میدان‌های فاقد مغزه‌گیری، زمینه استفاده از روش‌های یادگیری عمیق مبتنی بر چندوجهیت^۶ را فراهم می‌سازد.

کمبود داده مغزه به‌عنوان یکی از رایج‌ترین چالش‌ها در تحلیل‌های پتروفیزیکی و زمین‌شناسی، به شکل مستقیم توان مدل‌سازی مبتنی بر یادگیری ماشین و استخراج ارتباطات ریزمقیاس را محدود می‌کند. هرچند داده‌های چاه‌پیمایی در بیشتر میدان‌ها در دسترس هستند، اما این داده‌ها فاقد ویژگی‌های بافتی و ساختاری موجود در تصاویر مغزه بوده و بنابراین برای مدل‌هایی که نیازمند اطلاعات چندوجهی هستند، کفایت لازم را ندارند. از این جهت، فاز چهارم پژوهش نقش کلیدی خود را از طریق پر کردن شکاف میان دو حوزه داده‌ای ایفا می‌کند. در این فاز:

⁴Data Governance

⁵Multimodal Dataset

⁶Multimodality

- از تصاویر مغزه میدان مبدأ (میدانی که داده تصویری در آن وجود دارد) جهت یادگیری الگوهای بصری، بافتی و ساختاری استفاده می‌شود.

- از داده‌های چاه‌پیمایی میدان مقصد (فاقد تصویر مغزه) به‌عنوان نماینده ویژگی‌های ژئوفیزیکی و پتروفیزیکی میدان هدف بهره گرفته می‌شود.

این تلفیق دوگانه، زمینه تولید تصاویر مغزه مصنوعی را فراهم می‌کند که ضمن سازگار بودن با ویژگی‌های سنگ‌شناسی میدان هدف، از لحاظ بصری و ساختاری نیز منطبق بر الگوهای دیده‌شده در داده‌های واقعی میدان مبدأ هستند.

۳-۴-۱ چارچوب مفهومی تولید داده‌های مصنوعی

چارچوب پیشنهادی متکی بر ایده استفاده از مدل‌های مولد (Generative Models) به‌ویژه مدل‌های مبتنی بر شبکه‌های مولد تخاصمی (GANs)، مدل‌های انتشار (Diffusion Models)، یا شبکه‌های تبدیل‌کننده شرطی (Conditional Transformers) است. در این چارچوب، داده‌های چاه‌پیمایی میدان مقصد به‌عنوان ورودی شرطی (Conditioning Input) در نظر گرفته شده و مدل مولد تلاش می‌کند تا تصویری تولید کند که به‌لحاظ آماری و ساختاری با مغزه‌های میدان مبدأ مشابه باشد، اما با شرایط سنگ‌شناختی میدان مقصد سازگاری داشته باشد.

به‌طور کلی، فرایند تولید داده مصنوعی شامل سه مؤلفه اصلی است:

مدلسازی رابطه میان داده‌های چاه‌پیمایی و ویژگی‌های تصویری

در این بخش، با استفاده از مدل‌های یادگیری عمیق، نگاشتی از فضای داده‌های عددی چاه‌پیمایی به فضای ویژگی‌های بصری استخراج می‌شود. داده‌هایی نظیر GR، RHOB، NPHI، DT، PEF و سایر پارامترهای پتروفیزیکی می‌توانند نقش شاخصی در تعیین ساختار، بافت، تخلخل، رخساره و زون‌های ریزشی در تصاویر مغزه داشته باشند. هدف، یادگیری یک نمایش مشترک (Shared Latent Space) است که هر دو نوع داده را در یک فضای نهفته یکپارچه مدل می‌کند.

استخراج الگوهای ساختاری از تصاویر مغزه واقعی میدان مبدأ

برای آنکه داده‌های مصنوعی کیفیت بصری و ساختاری لازم را داشته باشند، مدل باید قادر به بازنمایی دقیق ویژگی‌هایی همچون لایه‌بندی، تغییرات بافتی، شکستگی‌ها، سیمانی‌شدگی، تیپ‌های رسوبی و

تغییرات دانه‌بندی باشد. برای این منظور، تصاویر مغزه واقعی از میدان مبدأ تحت پردازش‌های زیر قرار می‌گیرند:

- استخراج ویژگی‌های چندمقیاسی با استفاده از شبکه‌های کانولوشنی (CNNs) و مدل‌های هیبریدی.
- یادگیری مدل‌های توزیعی و ساختاری داده تصویری برای استفاده در مرحله تولید.

تولید تصاویر مغزه مصنوعی برای میدان مقصد

در مرحله نهایی، مدل مولد با دریافت ورودی چاه‌پیمایی میدان مقصد، تصویری تولید می‌کند که نه تنها ساختارهای بصری مشابه میدان مبدأ را بازتاب می‌دهد، بلکه با خواص پتروفیزیکی میدان مقصد نیز سازگار است. هدف از این مرحله، تولید تصاویری با ویژگی‌های زیر است:

۳-۴-۲ مزایا و پیامدهای پژوهشی فاز چهارم

توسعه این چارچوب چندوجهی مصنوعی، مجموعه‌ای از دستاوردهای نظری و کاربردی را برای حوزه پتروفیزیک، ژئومکانیک و زمین‌شناسی رسوبی رقم می‌زند. مهم‌ترین پیامدها شامل موارد زیر است:

رفع محدودیت‌های نمونه‌برداری در میدان‌های فاقد مغزه

در بسیاری از میدان‌های نفتی، به دلایلی همچون هزینه‌های بسیار بالا، ریسک‌های فنی، شرایط نامساعد چاه یا راهبردهای توسعه، امکان مغزه‌گیری در تمامی چاه‌ها وجود ندارد. رویکرد پیشنهادی با فراهم‌سازی داده‌های مصنوعی با کیفیت بالا، این چالش را به‌صورت بنیادین برطرف می‌کند.

ایجاد بستر برای مدل‌های چندوجهی پیشرفته

در سال‌های اخیر، مدل‌های مبتنی بر چندوجهیت نظیر مدل‌های ترکیبی (Fusion Models) و مدل‌های مبتنی بر اشتراک‌گذاری دانش (Knowledge-Sharing Models) نقش مهمی در تحلیل مخازن یافته‌اند. تولید مجموعه داده مصنوعی چندوجهی به‌عنوان ورودی این مدل‌ها، ظرفیت ایجاد مدل‌هایی دقیق‌تر و مقیاس‌پذیرتر را ممکن می‌سازد.

امکان انتقال دانش میان میدان‌ها

با استفاده از رویکرد پیشنهادی، می‌توان از اطلاعات تصویری یک میدان به‌عنوان «دانش منبع» برای آموزش مدل‌هایی استفاده کرد که در میدان‌های فاقد مغزه کارآمد هستند. این موضوع گامی عملی در جهت یادگیری انتقالی (Transfer Learning) در حوزه زمین‌شناسی محسوب می‌شود.

۳-۴-۳ جمع‌بندی

فاز چهارم پژوهش با تمرکز بر توسعه چارچوبی برای تولید مجموعه داده چندوجهی مصنوعی، گامی بنیادی در جهت مقابله با چالش فقدان داده‌های تصویری در بسیاری از میداین نفتی محسوب می‌شود. این چارچوب علاوه بر بازتولید واقع‌گرایانه ویژگی‌های تصویری، داده‌های مصنوعی را با شرایط سنگ‌شناسی و پتروفیزیکی میدان مقصد سازگار کرده و بستری نوین برای تحلیل‌های مبتنی بر چندوجهیت در حوزه یادگیری ماشین فراهم می‌آورد. خروجی این فاز می‌تواند به‌عنوان یک منبع داده قابل‌اتکا در مراحل بعدی پژوهش، شامل مدل‌سازی، پیش‌بینی ویژگی‌های مخزنی و تحلیل‌های ساختاری مورد استفاده قرار گیرد.

۳-۵ فاز پنجم: پیاده‌سازی و ارزیابی چارچوب‌های پیشنهادی

بر دیتاست‌های مختلف در حوزه اکتشاف مخازن هیدروکربوری

در فاز نهایی، چارچوب‌های طراحی و توسعه‌یافته در مراحل پیشین پژوهش بر روی مجموعه‌ای از دیتاست‌های عمومی در حوزه طبقه‌بندی لیتولوژی پیاده‌سازی و ارزیابی می‌شوند. هدف اصلی از این مرحله، سنجش کارایی عملی چارچوب‌های پیشنهادی در شرایط داده‌ای متنوع و همچنین مقایسه عملکرد آن‌ها با روش‌های مطرح در ادبیات موضوع است. استفاده از دیتاست‌های عمومی و شناخته‌شده این امکان را فراهم می‌سازد که نتایج حاصل از پژوهش با نتایج گزارش‌شده در مقالات پیشین به‌صورت منصفانه و قابل‌اتکا مقایسه گردد و جایگاه روش‌های پیشنهادی از نظر دقت، پایداری و کارایی مشخص شود.

دیتاست‌های مورد استفاده در این فاز شامل دو دسته اصلی هستند. دسته نخست شامل تصاویر مغزه‌های حفاری (Core Images) همراه با برچسب‌های لیتولوژیکی است که اطلاعات باارزشی از ویژگی‌های بافتی و ساختاری سنگ‌ها در اختیار قرار می‌دهند. دسته دوم شامل داده‌های چاه‌پیمایی به‌همراه

برچسب‌های لیتولوژی است که به صورت سری‌های عددی از اندازه‌گیری‌های ژئوفیزیکی در طول چاه ثبت شده‌اند. هر یک از این دو نوع داده، جنبه‌های متفاوتی از خصوصیات مخزن را بازتاب می‌دهند و در نتیجه استفاده از آن‌ها امکان ارزیابی جامع‌تری از قابلیت‌های چارچوب‌های پیشنهادی فراهم می‌کند. در بخش ۴-۲ برخی از مهم‌ترین دیتاست‌های عمومی مورد استفاده در این پژوهش معرفی شده‌اند.

پیاده‌سازی چارچوب‌های پیشنهادی بر روی چندین دیتاست با ماهیت‌های متفاوت، علاوه بر فراهم کردن امکان مقایسه با روش‌های رقیب، نقش مهمی در ارزیابی میزان استواری و تعمیم‌پذیری این چارچوب‌ها ایفا می‌کند. در واقع، یک چارچوب کارآمد باید قادر باشد در مواجهه با داده‌هایی که از منابع مختلف، شرایط زمین‌شناسی متفاوت و ساختارهای داده‌ای گوناگون به دست آمده‌اند، عملکرد قابل قبولی از خود نشان دهد. از این‌رو، بررسی عملکرد مدل‌ها در محیط‌های داده‌ای متنوع می‌تواند نقاط قوت و محدودیت‌های آن‌ها را آشکار ساخته و مسیرهای بالقوه برای بهبود و توسعه بیشتر روش‌های پیشنهادی را مشخص کند.

در این فاز، علاوه بر پیاده‌سازی چارچوب‌ها، فرآیند ارزیابی نیز با استفاده از معیارهای استاندارد یادگیری ماشین و طبقه‌بندی انجام می‌شود تا تصویری دقیق از عملکرد مدل‌ها ارائه گردد. نتایج به دست آمده نه تنها امکان مقایسه کمی با پژوهش‌های پیشین را فراهم می‌کند، بلکه مبنایی برای تحلیل عمیق‌تر رفتار مدل‌ها در مواجهه با انواع مختلف داده‌های زمین‌شناسی فراهم می‌آورد. در نهایت، یافته‌های این مرحله می‌تواند به عنوان شواهد تجربی برای اثبات کارایی چارچوب‌های پیشنهادی و همچنین ارائه پیشنهادهایی برای بهبود آن‌ها در کاربردهای واقعی صنعت اکتشاف مخازن هیدروکربوری مورد استفاده قرار گیرد.

فصل چهارم

جمع بندی

در این فصل، ابتدا فازهای مختلف پیشنهاد رساله مورد بررسی و جمع‌بندی قرار می‌گیرد تا با یکپارچه‌سازی آن‌ها، تصویری منسجم و نظام‌مند از چارچوب کلی پژوهش ترسیم شود. در ادامه، برنامه زمان‌بندی پیشنهادی برای اجرای رساله ارائه خواهد شد.

۴-۱ جمع‌بندی و یکپارچه‌سازی فازهای پیشنهاد رساله

در این پژوهش، فازهای مختلف تحقیق به گونه‌ای طراحی و سازمان‌دهی شده‌اند که در مجموع یک مسیر منسجم و هدفمند را برای دستیابی به چارچوبی جامع در طبقه‌بندی لیتولوژی مبتنی بر یادگیری ماشین شکل می‌دهند. در فاز اول، تمرکز بر چالش‌های واقعی و عملیاتی موجود در میداین هیدروکربوری قرار می‌گیرد. در شرایط عملیاتی، معمولاً از داده‌های یک میدان برای پیش‌بینی لیتولوژی در میداین دیگر استفاده می‌شود. در چنین شرایطی، تفاوت‌های زمین‌شناسی، تغییرات محیط رسوبی و ناهمگونی مخازن سبب بروز مشکل اختلاف دامنه میان اطلاعات میداین مختلف می‌شود. برای حل این چالش، از رویکردهای تطبیق و تعمیم دامنه برای مدیریت اختلاف توزیع داده‌ها میان میداین مختلف استفاده می‌شود. فاز دوم به مدیریت احتمال وجود کلاس‌های ناشناخته لیتولوژیکی در میدان مقصد اختصاص دارد. در چنین شرایطی، استفاده از رویکردهای طبقه‌بندی مجموعه‌باز برای شناسایی و مدیریت کلاس‌های ناشناخته ضروری است.

در فاز سوم، به مهم‌ترین الزامات پیاده‌سازی صنعتی سامانه‌های هوشمند می‌پردازد. این الزامات هرچند در فضای آکادمیک کمتر مورد توجه قرار گرفته‌اند، اما در محیط‌های صنعتی نقشی کاملاً حیاتی و تعیین‌کننده دارند. حفظ محرمانگی داده‌ها یکی از الزامات اساسی در این حوزه محسوب می‌شود. رویکردهای مبتنی بر یادگیری مشارکتی امکان آموزش مدل‌ها بدون تبادل مستقیم داده‌های حساس را فراهم می‌کند. این چارچوب به شرکت‌ها و سازمان‌ها اجازه می‌دهد در عین حفظ محرمانگی داده‌ها، از مزایای همکاری‌های بین سازمانی و داده‌های گسترده آموزشی بهره‌مند شوند.

در فاز چهارم دامنه پژوهش از سطح مدیریت کمبود داده فراتر رفته و به توسعه چارچوبی به منظور تولید مجموعه داده مصنوعی می‌پردازد. این چارچوب نه تنها راه‌حلی پایدار برای چالش کمبود داده ارائه می‌کند، بلکه امکان بهره‌برداری هم‌زمان از اطلاعات چاه‌پیمایی و تصاویر مغزه را برای یک میدان فراهم می‌سازد. در فاز نهایی، چارچوب‌های طراحی و توسعه‌یافته در مراحل پیشین پژوهش بر روی مجموعه‌ای از دیتاست‌های عمومی در حوزه طبقه‌بندی لیتولوژی پیاده‌سازی و ارزیابی می‌شوند. در نتیجه، فازهای مختلف این پژوهش در قالب یک مسیر پیوسته و منسجم طراحی شده‌اند که از مواجهه با چالش‌های

بنیادی پژوهشی تا پرداختن به ملاحظات عملیاتی، امنیتی و اجرایی در حوزه طبقه‌بندی لیتولوژی را در بر می‌گیرد. این یکپارچگی، چارچوبی جامع برای توسعه و به‌کارگیری مدل‌های هوش مصنوعی در کاربردهای واقعی اکتشاف و ارزیابی مخازن هیدروکربوری فراهم می‌سازد.

۲-۴ زمان‌بندی پیشنهادی اجرای رساله

در این بخش، برنامه‌ی زمان‌بندی پیشنهادی برای پیشبرد و تکمیل فازهای معرفی شده در پیشنهاد رساله ارائه می‌شود. جزئیات این زمان‌بندی در جدول ۴-۱ تشریح شده است.

جدول ۴-۱: زمان‌بندی پیشنهادی پیشبرد و تکمیل فازهای مختلف رساله در بازه ۲۴ ماهه

عنوان فعالیت	۱	۲	۳	۴	۵	۶	۷	۸	۹	۱۰	۱۱	۱۲	۱۳	۱۴	۱۵	۱۶	۱۷	۱۸	۱۹	۲۰	۲۱	۲۲	۲۳	۲۴	
بررسی مطالعات پیشین																									
طراحی چارچوب فاز اول																									
پیاده‌سازی فاز اول																									
طراحی چارچوب فاز دوم																									
پیاده‌سازی فاز دوم																									
تدوین و ارسال مقاله اول																									
طراحی چارچوب فاز سوم																									
پیاده‌سازی فاز سوم																									
طراحی چارچوب فاز چهارم																									
پیاده‌سازی فاز چهارم																									
تدوین و ارسال مقاله دوم																									
نگارش رساله																									
اصلاحات و آماده‌سازی دفاع																									

منابع و مراجع

- [1] Sun, Youzhuang, Pang, Shanchen, Li, Hengxiao, Qiao, Sibbo, and Zhang, Yongan. Enhanced lithology classification using an interpretable shap model integrating semi-supervised contrastive learning and transformer with well logging data: Sun, pang, li, qiao, and zhang. *Natural Resources Research*, 34(2):785–813, 2025.
- [2] Li, Yang, Chen, Jiayao, Fang, Qian, Zhang, Dingli, and Huang, Wengui. Towards automated lithology classification in natm tunnel: A data-driven solution for multi-dimensional imbalanced data. *Rock Mechanics and Rock Engineering*, 58(2):2349–2366, 2025.
- [3] Yang, Xu, Dong, Shaoqun, Quan, Junkun, Xu, Tao, Kong, Huangshuai, Zeng, Lianbo, Xiong, Guohao, and Bi, Ruixiang. Lithology identification using stratigraphic continuity and petrophysical features of well logs. *Results in Engineering*, p. 109913, 2026.
- [4] Sun, Xiaohui, Zhang, Lina, Wang, Jintang, Wang, Zhiyuan, and Sun, Baojiang. Attention-based bidirectional gated recurrent unit neural networks for lithology identification from well-logging data: Sun, zhang, j. wang, z. wang and sun. *Natural Resources Research*, pp. 1–23, 2026.
- [5] Yousefimehr, Behnam and Ghatee, Mehdi. A systematic survey and empirical comparison of hybrid methods for imbalanced fraud detection: Combining resampling and machine learning. *AUT Journal of Mathematics and Computing*, 2025.

- [6] Yousefimehr, Behnam, Ghatee, Mehdi, Seifi, Mohammad Amin, Fazli, Javad, Tavakoli, Sajed, Rafei, Zahra, Ghaffari, Shervin, Nikahd, Abolfazl, Gandomani, Mahdi Razi, Orouji, Alireza, et al. Data balancing strategies: A survey of resampling and augmentation methods. arXiv preprint arXiv:2505.13518, 2025.
- [7] Li, Hengxiao, Liu, Yahui, and Liu, Lu. Unsupervised domain adaptation for lithology classification using dynamic entropy-based prototype learning. *Engineering Applications of Artificial Intelligence*, 161:112150, 2025.
- [8] Shi, Yu, Liao, Junqiao, Gan, Lu, and Tang, Rongjiang. Lithofacies prediction from well log data based on deep learning: A case study from southern sichuan, china. *Applied Sciences*, 14(18), 2024.
- [9] Mousavi, Seyed Hamid and Hosseini-Nasab, Seyed. A novel approach to classify lithology of reservoir formations using grownnet and deep-insight with physic-based feature augmentation. *Energy Science & Engineering*, 12:4453–4477, 10 2024.
- [10] Dai, Chuanli, Si, Xu, and Wu, Xinming. FlexLogNet: A flexible deep learning-based well-log completion method of adaptively using what you have to predict what you are missing. *Computers and Geosciences*, 191:105666, September 2024.
- [11] Hallam, Antony, Mukherjee, Debajoy, and Chassagne, Romain. Multivariate imputation via chained equations for elastic well log imputation and prediction. *Applied Computing and Geosciences*, 14:100083, 2022.
- [12] Wang, Aiting, Zhao, Shuyu, Xie, Kai, Wen, Chang, Tian, Hong-ling, He, Jian-Biao, and Zhang, Wei. Attention mechanism-enhanced graph convolutional neural network for unbalanced lithology identification. *Scientific Reports*, 14, 07 2024.
- [13] Jamshidi Gohari, Mohammad Saleh, Emami Niri, Mohammad, Sadeghnejad, Saeid, and Ghiasi-Freez, Javad. An ensemble-based machine learning solution for imbalanced multiclass dataset during lithology log generation. *Scientific Reports*, 13, 12 2023.

- [14] Zhu, Xinyi, Zhang, Hongbing, Zhu, Rui, Ren, Quan, and Zhang, Lingyuan. Classification with noisy labels through tree-based models and semi-supervised learning: A case study of lithology identification. *Expert Systems with Applications*, 240:122506, 2024.
- [15] Feng, Xiaoyue, Luo, Hongmei, Wang, Changjiang, and Gu, Hanming. Reducing the effect of incorrect lithology labels on the training of deep neural networks for lithology identification. *Mathematical Geosciences*, 56, 09 2023.
- [16] Zhang, Zhuo, Tang, Jizhou, Fan, Bo, Zhao, Xianzheng, Jin, Fengming, Chen, Changwei, Chen, Zi, Chen, Shengnan, Song, Yu, and Yang, Jin. An intelligent lithology recognition system for continental shale by using digital coring images and convolutional neural networks. *Geoenergy Science and Engineering*, 239:212909, 2024.
- [17] Dong, Shaoqun, Yang, Xu, Xu, Tao, Zeng, Lianbo, Chen, Shutong, Wang, Leting, Niu, Yanchun, and Xiong, Guohao. Semi-supervised neural network for complex lithofacies identification using well logs. *IEEE Transactions on Geoscience and Remote Sensing*, 2024.
- [18] Bormann, Peter, Aursand, Peder, and Dilib, Fahad. FORCE Machine Learning Competition. <https://github.com/bolgebrygg/Force-2020-Machine-Learning-competition>, November 2020.
- [19] Shi, Yu, Liao, Junqiao, Gan, Lu, and Tang, Rongjiang. Lithofacies prediction from well log data based on deep learning: a case study from southern sichuan, china. *Applied Sciences*, 14(18):8195, 2024.
- [20] Li, Jia-Yu, Tang, Ji-Zhou, Zhao, Xian-Zheng, Fan, Bo, Jiang, Wen-Ya, Song, Shun-Yao, Li, Jian-Bing, Chen, Kai-Da, and Zhao, Zheng-Guang. A large-scale, high-quality dataset for lithology identification: Construction and applications. *Petroleum Science*, 2025.

- [21] Daneshpour, Ali, Yousefimehr, Behnam, and Ghatee, Mehdi. Balanced learning with optimized extra trees classifier for reliable lithology identification in imbalanced well log data. in 2025 15th International Conference on Computer and Knowledge Engineering (ICCKE), pp. 1–6. IEEE, 2025.
- [22] Dai, Chuanli, Si, Xu, and Wu, Xinming. Flexlognet: A flexible deep learning-based well-log completion method of adaptively using what you have to predict what you are missing. *Computers & Geosciences*, 191:105666, 2024.
- [23] Hallam, Antony, Mukherjee, Debajoy, and Chassagne, Romain. Multivariate imputation via chained equations for elastic well log imputation and prediction. *Applied Computing and Geosciences*, 14:100083, 2022.
- [24] Khan, Saud Qadir and Kirmani, Farzain Ud Din. Applicability of deep neural networks for lithofacies classification from conventional well logs: An integrated approach. *Petroleum Research*, 9(3):393–408, 2024.
- [25] de Aguiar¹, Lucas Gabriel Silva, de Matos¹, Maurício Laurindo, de Oliveira¹, Jadson Muniz, and da Silva Canário¹, Rodrigo. Petrophysical guided preconditioning applied to electrofacies classification by machine learning. 2021.
- [26] Yurdem, Betul, Kuzlu, Murat, Gullu, Mehmet Kemal, Catak, Ferhat Ozgur, and Tabasum, Maliha. Federated learning: Overview, strategies, applications, tools and future directions. *Heliyon*, 10(19), 2024.

واژه‌نامه‌ی فارسی به انگلیسی

سنگ‌شناسی Lithology	آ
م	آزمون Test
ماتریس درهم ریختگی . . Confusion Matrix	آموزش Train
مجموعه داده Dataset	استواری Robustness
مدل‌های انتشار Diffusion Models	اعتبارسنجی Validaton
ه	ت
هوش مصنوعی قابل اعتماد . Trustworthy AI	تخلخل Porosity
ی	تراوایی Permeability
یادگیری با چندنمونه . . Few-Shot Learning	تطبیق دامنه Domain Adaptation
یادگیری بدون ناظر Unsupervised Learning	تعمیم دامنه Domain Generalization
یادگیری بدون نمونه . . Zero-Shot Learning	ح
یادگیری عمیق Deep Learning	حاکمیت داده Data Governance
یادگیری فعال Active Learning	س
یادگیری ماشین Machine Learning	سوگیری Bias
یادگیری مشارکتی Federated Learning	س

یادگیری نظارت‌شده . . Supervised Learning

یادگیری نیمه نظارت‌شده . Semi-Supervised
Learning

واژه‌نامه‌ی انگلیسی به فارسی

A	Lithology سنگ‌شناسی
Active Learning یادگیری فعال	M
B	Machine Learning یادگیری ماشین
Bias سوگیری	P
D	Permeability تراوایی
Data Governance حاکمیت داده	Porosity تخلخل
Dataset مجموعه داده	R
Deep Learning یادگیری عمیق	Robustness استواری
Domain Adaptation تطبیق دامنه	S
Domain Generalization تعمیم دامنه	Semi-Supervised . . . یادگیری نیمه نظارت‌شده
Diffusion Models مدل‌های انتشار	Learning
F	Supervised Learning . . یادگیری نظارت‌شده
Federated Learning یادگیری مشارکتی	T
Few-Shot Learning . . . یادگیری با چندنمونه	Test آزمون
L	Trian آموزش

هوش مصنوعی قابل اعتماد . Trustworthy AI

اعتبارسنجی Validaton

U**Z**

یادگیری بدون ناظر Unsupervised Learning

V

یادگیری بدون نمونه . . Zero-Shot Learning

Abstract

Efficient and low-risk exploration of hydrocarbon reservoirs remains one of the strategic challenges in the oil and gas industry. Despite significant advancements over recent decades, conventional geological data-interpretation methods still face limitations such as reliance on expert knowledge, the high complexity of reservoir structures, uncertainties in subsurface modeling, and the substantial costs associated with exploratory operations. In recent years, deep learning approaches that can automatically extract complex patterns from large-scale datasets have opened new opportunities for improving hydrocarbon reservoir exploration. Nevertheless, designing robust, optimized, and secure frameworks remains a fundamental challenge in this domain. The primary objective of this research is to develop efficient and innovative deep-learning-based frameworks to enhance and streamline the hydrocarbon exploration workflow. In the first phase, the operational challenges of lithology prediction across different fields are investigated. Geological variations and reservoir heterogeneity lead to discrepancies in data distributions; therefore, domain adaptation and generalization techniques are employed to address these differences. In the second phase, considering the potential presence of previously unseen lithological classes in the target field, open-set classification approaches are adopted to identify and properly manage such classes. The third phase examines the key requirements for industrial deployment of intelligent systems. In this context, data confidentiality is preserved through federated learning, enabling model training without exchanging sensitive information. In the fourth phase, the objective is to develop a synthetic dataset using diffusion models that integrates well-logging data and core images for a given field, enabling comprehensive and multi-modal reservoir characterization. Finally, in the last phase of the research, the effectiveness and generalizability of the proposed frameworks are evaluated by implementing them on various datasets within the domain of hydrocarbon reservoir exploration. The integration of these phases enhances the reliability, robustness, and practical acceptance of artificial intelligence models in exploration and

reservoir evaluation applications.

Key Words:

Lithology, Deep Learning, Federated Learning, Domain Generalization, Trustworthy AI



Amirkabir University of Technology
(Tehran Polytechnic)

Department of Mathematics and Computer Science

**Proposal submitted in partial fulfilment of the requirements for
the Degree of Doctor of Philosophy**

**Domain Adaptation for
privacy-preserving deep networks for
hydrocarbon reservoir exploration data
processing**

By
Ali Daneshpour

Supervisors
Dr. Mehdi Ghatee and Dr. Mohammad Hassan
Shirali-Shahreza

Advisor
Dr. Ali Akbar Nourian

April 2026